

NeuroPLC: 从 PyTorch 到 IEC 61131-3 SCL 的结构可验证编译及其在工业 PLC 上的应用

刘甫悦, 桂林电子科技大学, 广西桂林 541004

摘要

编译器能否证明部署到 PLC 上的神经网络代码忠实地保留了训练模型的行为? 本文证明, 答案不取决于编译器工程, 而取决于模型的架构。我们提出了结构可验证神经网络 (Structurally Verifiable Neural Network, SVNN) 框架: 两个条件——操作类型封闭性和单变量有界性——足以让编译器仅凭模型参数计算出对所有输入有效的有限逐输出误差界 (定理 2)。标准 MLP 可证明不满足这些条件 (命题 1); 采用 B 样条激活函数的 Kolmogorov-Arnold 网络 (KAN) 则满足。违反条件使紧致界计算成为 NP 难问题 (定理 5); 满足更强的收缩条件则产生随深度改善的泛化界 $\Delta L \leq O(\gamma^L/\sqrt{n})$ (定理 6)。SVNN 框架由此定义了一条可编译前沿——一条原则性的边界, 将部署行为可在设计时认证的架构与需要运行时测试的架构分隔开来。

我们通过 NeuroPLC 实例化 SVNN——这是首个将 PyTorch 模型翻译为西门子 S7-1200/1500 IEC 61131-3 SCL 的基于 IR 的编译器。三种验证机制组合为端到端保证: (i) 一次性 Z3 SMT 证明, 确认 4/6 种 IR 操作类型模板对所有可能参数均正确; (ii) 512 个逐函数 Z3 证明组装为机器可检查的端到端证书, 由约 200 行可信检查器验证; (iii) 符号结构仿射算术, 比区间算术紧致 $2.2\times$ (与 $\sqrt{d}$ 随机权重基线相比达 $3.1\times$, 安全因子 $8.5\times$)。KAN 的分解是结构必然性: 同规模 KAN 与 MLP 分别获得 512/512 与 0/16 的 Z3 可验证组件。该框架扩展到 ChebyKAN (切比雪夫多项式基, 命题 2, 496/512 Z3 可验证)。三层 KAN 实现 608/608 Z3 验证 (100%), NeuroPLC 的 DA 界比 CROWN-IBP 紧致 $85\times$, 生成的 SCL 在 TIA Portal V21 中以 0 错误、0 警告编译 (45.2 KB, S7-1200 预算的 90.4%)。在 CWRU (99.93%)、XJTU-SY 全寿命试验 (91.7% 微调, 512/512 Z3 保留) 和 MNIST (98.6%) 上验证。

Index Terms

Kolmogorov-Arnold 网络, IEC 61131-3, 结构化文本 (SCL), 神经网络编译器, 结构可验证性, 仿射算术, SMT 验证, 组合认证, 切比雪夫多项式网络, 泛化界。

I. 引言

一个在 CWRU 数据集上达到 99.93% 故障诊断准确率的神经网络——孤立地看——无法部署到控制其监测设备的 PLC 上。其原因不是偶发的, 而是结构性的: PLC 以确定性扫描周期执行 IEC 61131-3 结构化控制语言 (SCL), 而非 PyTorch; 其工作内存预算 (西门子 S7-1200 CPU 1211C 仅 50 KB) 排除了 ML 推理框架所需的运行时库; 而——本文要解决的问题——没有任何现有工具能够认证编译后的神经网络在工业控制器的定点 REAL 算术中保留其训练行为。现有 ML $\rightarrow$ PLC 工具 (RTNNigen [1]、MLconverter [2]、ICSML [3]) 仅提供经验测试集验证; 唯一的 KAN-on-PLC 先例 (Corrêa [4], USP 2024) 依赖通过 Snap7 的分布式 PC-to-PLC 通信, 而非本地 SCL 编译, 且未提供任何正确性保证。通用编译器 (TVM、ONNX Runtime) 无法以 IEC 61131-3 为目标。四条独立研究路线汇聚于同一观察——KAN 的单变量 B 样条结构本质上适合基于 LUT 的硬件评估——涵盖 FPGA (KANELE [5], ISFPGA 2026 最佳论文)、MCU (LUT-KAN [6])、TinyML (KAN-SoC [7]) 和形式化验证 (Schwartz 等 [8])。然而, 无一提供具有设计时认证的端到端 PyTorch-to-IEC 61131-3 编译器——这正是本文交付的组合。

本文的结构洞察是：认证差距不是编译器工程问题——而是一个架构问题。编译器能否计算设计时正确性保证，取决于网络架构是否分解为误差传播封闭的操作。我们通过 **SVNN** 框架 (§III) 形式化了这一洞察：两个结构条件（操作类型封闭性、单变量有界性）足以让编译器为验证域内所有输入计算有限、参数可计算的逐输出误差界（定理 2）。KAN 满足这些条件；采用 SiLU/Sigmoid/Tanh 激活的标准 MLP 可证明不满足（命题 1）。SVNN 由此定义了一条**可编译前沿**：将部署行为可在设计时认证的架构与需要运行时测试的架构分隔的原则性边界。

我们在 NeuroPLC 中实现了这一框架——这是首个将 PyTorch KAN 翻译为西门子 S7-1200/1500 SCL 的基于 IR 的编译器。编译器是 SVNN 的概念验证——而非其主要贡献。三种验证机制建立保证：（1）Z3 SMT 编译器模板验证（一次性，4/6 种 IR 操作类型证明）；（2）组合证书（512 个逐函数证明 → 约 200 行端到端可信检查器）；（3）符号结构仿射算术（比区间算术紧致 $2.2\times$ ，与 $\sqrt{d}$ 随机权重基线相比达 $3.1\times$ ）。KAN 的 B 样条分解是结构必然性：同规模 MLP [28, 16, 4] 仅 0/16 Z3 可验证组件，而 KAN 为 512/512。

Liu 等 [9] 提出的 KAN 将固定激活函数（ReLU）替换为置于网络边上的可学习 B 样条函数——这一结构差异是可验证性的关键。B 样条激活本质上是分段多项式，使得确定性查表（LUT）编译成为可能，且具有保证的误差界（ $\varepsilon \leq M_2 \Delta^2 / 8$ ）。每条 B 样条边仅需 68 字节 LUT 存储即可编译 [6]，在资源受限硬件上实现 7–25 $\times$ 推理加速。

先前 ML→PLC 工具确立了编译是可能的，但未解决是否可以认证的问题。RTNNIgen [1] 将 Keras 模型转换为 IEC 61131-3 结构化文本；MLconverter [2] 以 scikit-learn 为 ABB 控制器目标。两者仅提供经验测试集验证——一种从 ML 基准测试继承的正确性模型，对安全关键 PLC 部署不足。这些工具留下的差距不是实现差距（“它们不够努力”）——而是架构差距。我们的核心发现是：对于违反 SVNN 条件的架构，任何编译器工程都无法弥合这一差距（定理 5）。SVNN 框架解释了为何先前工具未提供保证——它们的目标架构在结构上排除了这种可能。NeuroPLC 是首个将训练后的 PyTorch 模型编译为 IEC 61131-3 SCL 并为这种编译何时可以认证提供形式化体系的编译器。

范围。NeuroPLC 将分类器 (KAN/MLP) 编译为 SCL。频域特征假设通过 DSP 预提取并通过 PROFINET/OPC UA 传输。PLC 端的时域子集也可编译 (E51)。本文贡献：

- 1) **理论（结构可验证性）**：提出 **SVNN** 框架 (§III)，形式化神经网络编译器能够提供设计时正确性保证的架构条件。两个充分条件（操作类型封闭性、单变量有界性）保证任意有限深度网络的有限、参数可计算的先验误差界；第三个收缩性精炼将其锐化为与深度无关的界（**定理 2**）。**命题 1** 确立了标准 MLP（ReLU、Sigmoid、Tanh）不满足这些条件。该框架将编译器设计问题从“能否验证任意架构？”重构为“哪些架构本质可验证？”——这一转变的影响远超 PLC 领域。
- 2) **系统（编译器）**：NeuroPLC——首个 PyTorch-to-西门子 SCL 编译器，使用与 KAN 的 SVNN 分解匹配的 6 操作 IR (§IV-B1)。生成的 SCL 在 TIA Portal V21 中于 S7-1200 和 S7-1500 上以 **0e 0w** 编译 (§IV-D)。
- 3) **算法（验证与优化）**：三种新型算法：(i) **符号结构仿射算术 (DA)**，通过保留权重矩阵符号结构实现比区间算术紧致 $2.2\times$ 的误差界（与 $\sqrt{d}$ 随机权重基线相比达 $3.1\times$ ，§IV-B9）；(ii) **分段感知 de Boor 界**，利用三次 B 样条二阶导数的分段线性结构实现 $6.0\times$ 逐段紧致（与 DA 组合达 $\sim 11.9\times$ 组合安全因子）；(iii) **自适应混合精度 LUT 分配**，贪心最大堆算法在等量存储下将最差情况 LUT 误差降低 71.6%，**定理 3** 通过交换论证证明其极小极大最优性 (§IV-B11)。
- 4) **理论（完备性）**：在充分性之外，我们建立了**计算必要性**（定理 5，§III-G）：违反条件 1 使紧致界计算成为 NP 难问题，证明 SVNN 条件不可放松。条件 3 产生随深度改善的泛化界 $\Delta_{\text{gen}} \leq O(\gamma^L / \sqrt{n})$ （定理 6，§III-H）。框架扩展到 **ChebyKAN**（命题 2）：496/512 Z3 可验证，100.0% CWRU 准确率。**E56**（3 层 KAN：608/608 Z3，99.60% acc）和 **E57**（NeuroPLC DA 比 CROWN-IBP 紧致 $85\times$ ）提供了深度缩放和验证器对比的经验证据。
- 5) **理论（正确性）**：**定理 1** (§IV) 通过对 IR 图的结构归纳保证为所有 6 种 IR 操作类型生成的 SCL 以可计算、

架构感知的误差界保留 PyTorch 语义。**定理 4** 通过鞅集中将保证推广到 L 层 KAN，证明在随机符号模型下误差仅随深度线性增长。

我们通过轴承故障诊断案例研究演示了该流水线：一个通过 VRM-KD [10] 从 48K 参数 1D-CNN 教师模型蒸馏得到的 6,148 参数 KAN 学生模型在 CWRU 测试集上达到 99.93% 准确率，压缩比 7.9 $\times$ 。在 XJTU-SY 全寿命数据（自然轴承退化，2020）上微调达到 91.7% 准确率，且 512/512 Z3 验证在适应后保留。总计 64 个实验（E1–E57 + V1–V7）覆盖压缩、泛化、正确性界、可扩展性、跨数据集迁移、跨架构验证和对抗鲁棒性。我们进一步讨论了 SVNN 框架与新兴 AI 功能安全标准（ISO/IEC TS 22440）和 IEC 61131-3 形式化验证工具（ESBMC-PLC+）的关系，将 NeuroPLC 置于更广泛的工业验证生态系统中。

II. 相关工作

A. 轴承故障诊断深度学习

三条工作线合力将 CWRU 轴承数据集 [11] 推向成熟基准。WDCNN [12] 以宽第一层卷积核确立了 99.9% 基准线；Zhang 等 [13] 将该范式扩展到一维残差网络；多尺度熵方法 [14], [15] 增加了非线性信号表征。三者共同建立了近乎完美的实验室轴承诊断标准。但 Rauber 等 [16] 揭示了许多接近 100% 结果中的训练/测试泄露——一个方法论警告。缺失的维度：99.9% 的准确率在实验室 GPU 上有何价值，如果推理无法在控制设备的 PLC 上运行？所有上述方法均假设配备 GPU 的工业 PC，而非 PLC。

B. Kolmogorov-Arnold 网络

Liu 等 [9] 引入 KAN，以可学习 B 样条替代固定激活函数——这一结构差异是后续所有 KAN 验证工作的基础。已有文献确立了 KAN 在轴承故障诊断中的有效性：Rigas 等 [17]、CNN-1D-KAN [18] 和 AdaptPolyKAN [19] 均在 CWRU 上达到竞争性准确率。但已有文献未涉及的是：KAN 的这一结构差异是否也使其编译可被形式认证——而不仅可被经验验证。这正是本文回答的问题。

KAN 硬件部署。 四条独立研究路线证明 KAN 的单变量 B 样条结构独特地适合基于 LUT 的硬件评估——这是 MLP 不具备的特性。FPGA 方面，KANELE [5]（ISFPGA 2026 最佳论文）通过量化 B 样条的 LUT 评估实现 2,700 $\times$ 加速。微控制器方面，LUT-KAN [6] 以预计算 LUT 操作替代 Cox-de Boor 递归（7–25 $\times$ 加速，每条边仅 68 字节）；KAN-SoC [7] 在电动汽车电池估算中实现比 MLP 高 10 $\times$ 的内存缩减（693 字节 vs. 6,807 字节）。PLC 方面，Corrêa [4]（USP 2024）提供了唯一的 KAN-on-PLC 先例：KAN [7, 5, 6] 通过 Snap7 分布式执行部署（PC 计算推理，PLC 通过以太网接收结果），在轴承分类任务上达到 88.5% 准确率。

这四项工作共同确立了 KAN 的 B 样条结构可跨硬件平台编译为 LUT 原语。但无一回答本文提出的问题：编译本身能否被认证？KANELE 和 LUT-KAN 经验性地验证了 LUT 范式；我们形式化了为何有效（定理 2）和何时失效（定理 5、命题 1）。Corrêa 证明了 KAN-on-PLC 的可行性，但未提供本地 SCL 编译、正确性保证或编译器工具链。NeuroPLC 是首个同时提供这三者的工作。

KAN 验证。 Schwartz 等 [8] 提出以 MILP 编码的 PWA 抽象用于 KAN 验证——在 SVNN Level 3 级别操作。Tankman [20] 证明了逐层 Lipschitz $P(\text{KAN}) \leq 1$ 作为结构性质。KAN4CBC [21] 展示了基于 SMT 的安全控制器合成。GloroKAN [22] 和 PolyKAN [23] 提供了互补的鲁棒性和压缩。这些与 NeuroPLC 协同：Schwartz 等的 MILP 验证可应用于由 NeuroPLC 编译的 KAN 以进行 SIL 3+ 认证，而 NeuroPLC 的 Level 2 算术界为 CI/CD 集成提供了快速、无需求解器的预认证。Tankman 的 Lipschitz 结果为条件 3（收缩性）提供了独立的理论支持。

C. 知识蒸馏

Hinton 等 [24] 引入温度缩放的软标签蒸馏。VRM [10]（ICCV 2025）通过动态亲和图剪枝的虚拟关系匹配复兴了基于关系的蒸馏——直接适用于 KAN 学生模型。Ren 等 [25] 应用多阶段剪枝-蒸馏于工业故障诊断。我

们贡献了首个将 VRM-KD 应用于 KAN 学生的工作：蒸馏是训练机制；贡献在于 KAN 的 $7.9\times$ 压缩不损害可验证性。

D. 面向工业控制器的神经网络编译

RTNNigen [1] (IECON 2024) 将 Keras 模型转换为 IEC 61131-3 ST, 并在 Beckhoff PLC 上演示了实时推理——这是目前 ML 推理能够在 PLC 上原生运行的最强证据。MLconverter [2] 将此范式扩展到 ABB 控制器的 scikit-learn 模型。ICSML [3] 提供原生 IEC 61131-3 ML 组件。共同的局限在于正确性模型：三者均通过测试集准确率验证, 继承了 ML 基准测试的经验验证范式。对于管理安全关键设备的 PLC 而言, 这是错误的正确性模型——不提供对未见输入的保证, 无法检测浮点漂移, 且不提供安全评估员可审计的证据。NeuroPLC 不仅仅是在这一系列上增加了另一个目标平台：它通过将编译器的输入限制在允许 SVNN 结构归纳的架构上, 将正确性模型从经验性转变为数学性 (定理 2)。没有自动化编译器能够将训练后的 PyTorch 网络翻译为具有设计时正确性认证的西门子 SCL。

E. IEC 61131-3 程序的形式化验证

ESBMC-PLC+ [26] 通过基于 SMT 的有界模型检验与 k 归纳提供了首个面向 IEC 61131-3 (LD、ST、SCL) 的开源统一验证框架。PLCReX [27] 将 ST/FBD 翻译为同步模型；PyLC+ [28] 将 PLCopen XML 编译为可验证 Python。这些工具验证逻辑属性 (互斥、不变式), 与 NeuroPLC 的数值正确性保证正交。两者可组合：NeuroPLC 生成的 SCL 可作为这些工具的输入 (§VI-B)。

F. 神经网络验证与定界

线性松弛方法——CROWN 和 DeepPoly [29], [30], 由 α - β -CROWN [31] 泛化为分支定界——逐层传播线性上下界, 在 ReLU 网络上实现紧致认证。**完备 SMT 验证器**——Reluplex [32] 和 Marabou [33]——通过激活模式案例拆分实现精确认证, 代价随 ReLU 单元数指数增长。**抽象解释** [34], [35] 通过抽象域提供可靠的过逼近。

NeuroPLC 的 SVNN 框架占据独特位置：它在设计时提供编译器计算、架构感知的界, 无需在部署时调用 LP 求解器或 SMT。关键区别：(1) 界依赖于编译后的 SCL 代码及其 LUT 近似, 而非原始浮点模型；(2) 条件 1 (操作类型封闭性) 是线性松弛和抽象解释工具不需要的结构要求；(3) SVNN 界是确定性的、参数可计算的——编译器认证到 SCL 的翻译, 而非模型鲁棒性。这些是互补的：CROWN/DeepPoly 验证原模型；SVNN 认证该模型的编译。

竞争定位。上述三种 ML-on-PLC 部署方法均不提供设计时正确性证书。领域特定编译器面向窄模型类但仅提供经验验证；通用推理引擎以 GPU/MCU 为目标, 无法生成 IEC 61131-3, 且运行时库本身超 PLC 内存预算数个数量级；形式化验证工具验证原模型鲁棒性但不编译或不认证编译步骤。NeuroPLC 占据独特定位：它是**保持正确性的编译器**, 其设计由架构洞察 (SVNN) 驱动——可编译性是模型架构而非编译器工程的属性。”从如何验证任意架构到哪些架构本质可验证”这一重构是本文的首要贡献。

III. 神经网络的结构可验证性

我们现在形式化编译器设计过程中浮现的核心观察：神经网络编译器能否提供设计时正确性保证, 根本上取决于被编译的架构。本节定义了保持正确性编译可实现的架构类, 证明了 KAN 属于此类, 并展示了标准 MLP 不在此类。

注记 1 (可编译前沿)。SVNN 条件定义了**可编译前沿**——将部署行为可在设计时认证的神经架构与需要运行时测试的架构分隔的原则性边界。满足条件 1–2 的架构位于内部 (可认证侧)；违反任一条件的架构位于外部 (仅经验侧)。命题 1 确立了采用 SiLU、Sigmoid 或 Tanh 激活的标准 MLP 位于外部。这一前沿不是实现假象：它反映了哪些函数类允许闭式、编译器可计算的误差传播这一基本性质。

A. PLC 部署网络的验证挑战

工业 PLC 管理安全关键设备。在此类控制器上部署神经网络需要超越经验测试集准确率的正确性保证。现有 ML→PLC 工具 (RTNNigen [1]、MLconverter [2]、ICSML [3]) 不提供数学保证证明生成的 PLC 代码保留了训练模型的行为。

我们识别三个递增强度的部署验证级别:

- 1) **Level 1——运行时测试 (最弱)**: 在测试集上评估部署模型并报告准确率。不提供对未见输入的保证。
- 2) **Level 2——设计时误差界 (SVNN)**: 在编译时且不执行于硬件, 计算可证明的逐输出误差界 ε_i 。这是 NeuroPLC 提供的保证 (定理 1)。
- 3) **Level 3——机械化形式验证 (最强)**: 机器检查的证明 (Coq/Isabelle/Lean), 证明编译器保留到 IEEE 754 比特级的语义。TorchLean [36] 已实现此级别但对完整编译器流水线不可行。

Level 2——设计时误差界——是工业部署的合适级别。问题是: 哪些架构允许这样的界, 为什么?

B. 定义: 结构可验证神经网络 (SVNN)

定义 1 (结构可验证神经网络). 神经网络架构 $\mathcal{A}$ 关于编译器 C 是**结构可验证的** (SVNN), 如果对任意实例 $M \in \mathcal{A}$, 编译器能在设计时且不执行 M 于目标硬件的情况下, 计算出逐输出误差界 $\varepsilon_i(M, X)$ 使得:

$$\sup_{x \in X} \|M(x)_i - C(M)(x)_i\|_\infty \leq \varepsilon_i(M, X) \quad \forall i \in \{1, \dots, d_{\text{out}}\} \quad (1)$$

其中 $X \subset \mathbb{R}^{d_{\text{in}}}$ 是验证输入域, $C(M)$ 表示编译器生成的代码在 IEC 61131-3 REAL ($\equiv$ IEEE 754 binary32) 上执行的结果。

该定义捕捉了核心要求: 编译器必须在模型运行于 PLC 之前提供先验保证。

C. SVNN 的充分条件

定理 2 (SVNN 充分条件). 设 $\mathcal{A}$ 为前馈神经网络架构。若 $\mathcal{A}$ 满足下述条件 1 和 2, 则 $\mathcal{A}$ 是结构可验证的——对任意有限深度的实例, 编译器能从模型参数单独计算出有限逐输出误差界。若 $\mathcal{A}$ 额外满足收缩性精炼 (条件 3), 该界允许闭式、与深度无关的几何级数形式 $O(M_{\max} \cdot h^2 \cdot d_{\max} / (1 - \gamma))$ 。

标准 MLP 层 $\mathbf{h} = \sigma(W\mathbf{x} + \mathbf{b})$ 将仿射变换和逐点激活耦合, 违反条件 1。KAN 层在 IR 级自然分解为独立的 MatMul、BsplineLUT、StandardAct 和 Add 节点。

- 1) **操作类型封闭性 (条件 1)**。架构可分解为有向无环图, 其中每个节点要么是线性变换, 要么是逐元素单变量函数。该分解由编译器的 IR 提供 (§IV-B1)。
- 2) **单变量曲率界 (条件 2)**。每个逐元素单变量函数 f 在验证输入域上是 C^2 连续的, 且其二阶导数满足 $\sup_x |f''(x)| \leq M_f < \infty$ 。 M_f 必须仅从函数参数可计算。这使得 de Boor LUT 误差界 $\varepsilon_f = M_f h^2 / 8$ 成立。
- 3) **收缩组合 (条件 3, 精炼)**。每逐元素层的 Lipschitz 常数 $L_f^{(\ell)} = \sup_x |f'(x)|$ 与后续线性层的行和范数之积满足 $L_f^{(\ell)} \cdot \|W^{(\ell+1)}\|_{1,\infty} \leq \gamma < 1$ 。条件 3 将逐深度证书升级为与深度无关的证书; 对 SVNN 成员资格不是必需的。

证明。证明分四步进行。

步骤 1 (线性层精确性)。设 $y = Wx + b$ 为线性变换, 输入携带误差 δ_x 。编译输出为 $\tilde{y} = W\tilde{x} + b = Wx + b + W\delta_x$ 。因此 $\|\tilde{y} - y\|_\infty = \|W\delta_x\|_\infty \leq \|W\|_{1,\infty} \cdot \|\delta_x\|_\infty$ 。线性层不引入新误差源。

步骤 2 (逐元素有界性)。由 B 样条近似误差的 de Boor-Cox 递推 [37], 对任意 C^2 函数:

$$\|f - \tilde{f}\|_\infty \leq \frac{M_f \cdot h^2}{8} \quad (2)$$

若输入携带误差 δ_x ，由中值定理：

$$|f(x + \delta_x) - \tilde{f}(x + \delta_x)| \leq L_f \cdot |\delta_x| + \varepsilon_f \quad (3)$$

步骤 3（有限深度组合）。通过对层指标的结构归纳：

$$\Delta^{(\ell)} \leq L_f^{(\ell)} \cdot \|W^{(\ell)}\|_{1,\infty} \cdot \Delta^{(\ell-1)} + \varepsilon_f^{(\ell)} \cdot d_{\ell-1} \quad (4)$$

展开跨 L 层的递推：

$$\Delta^{(L)} \leq \sum_{\ell=1}^L \varepsilon_f^{(\ell)} \cdot d_{\ell-1} \cdot \prod_{j=\ell+1}^L (L_f^{(j)} \cdot \|W^{(j)}\|_{1,\infty}) \quad (5)$$

条件 1 的关键作用：它保证归纳遇到的每个节点都是已知类型，具有闭式误差规则。条件 1 和 2 下，每一项有限且可计算，产生可计算的设计时界 $\Delta^{(L)} < \infty$ 。

步骤 3b（深度均匀精炼——条件 3）。当 $\gamma < 1$ 时：

$$\Delta^{(L)} \leq \frac{\max_{\ell}(\varepsilon_f^{(\ell)} \cdot d_{\ell-1})}{1 - \gamma} = O\left(\frac{M_{\max} \cdot h^2 \cdot d_{\max}}{1 - \gamma}\right) \quad (6)$$

步骤 4（紧致性）。在实践中三个因素显著紧致化界：(1) 分段感知 M_2 ($6.0\times$)，(2) 符号结构仿射算术 ($3.1\times$)，(3) 自适应 LUT (71.6%)。组合安全因子约为 $11.9\times$ 。

注记 2 (SVNN 条件的近似必要性)。定理 5 (§III-G) 提供了形式答案：违反条件 1 使紧致界计算成为 NP 难问题。Richardson 定理 [38] 施加基本障碍：涉及 e^x 的表达式相等性不可判定。KAN 的 B 样条激活是分段多项式，完全避开此障碍。

注记 2（与定理 1 的关系）。定理 1 (§IV) 是 SVNN 框架对特定架构和编译器的具体实例化。定理 2 提供了一般原则：任何满足条件 1–2 的有限深度架构允许保持正确性的编译器。

注记 3（算术界 vs. MILP 验证）。SVNN 算术界 ($O(L \cdot M_{\max} \cdot h^2 \cdot d_{\max})$)，定理 2 与 Schwartz 等 [8] 的 PWA 抽象 +MILP 方法在验证代价-精度谱上互补。算术界 (Level 2) 在编译时可计算，MILP (Level 3) 提供精确认证。

D. KAN 满足 SVNN 条件

命题 1 (KAN 是结构可验证的)。每个 KAN 架构满足定理 2 的 SVNN 充分条件，因此是 SVNN 架构。训练后的 KAN 学生额外满足收缩性精炼（条件 3）。

证明。

条件 1（操作类型封闭性）。KAN 层自然分解为：

$$\text{KANLayer}(x)_j = \underbrace{b(x_j)}_{\text{Base path}} + \sum_{i=1}^{d_{\text{in}}} \underbrace{\phi_{j,i}(x_i)}_{\text{Spline path}} \quad (7)$$

每 KAN 层仅由逐元素单变量函数和线性组合构成——满足条件 1。

条件 2（单变量有界性）。三次 B 样条是 C^2 连续分段多项式。界 $M_2 = \max_x |\phi''(x)|$ 可从 B 样条控制点和节点向量直接计算：

$$\phi''(x) = \sum_{c=0}^{G+k-2} w_c \cdot B''_{c,3}(x) \quad (8)$$

解析上界仅依赖 B 样条次数和节点间距：

$$\max_x |B'_{c,4}(x)| \leq \frac{3}{h}, \quad \max_x |B''_{c,4}(x)| \leq \frac{6}{h^2} \quad (9)$$

表 I

SVNN 可编译前沿下的架构分类学。内部架构允许编译器计算设计时正确性证书；外部架构需要运行时测试。

	架构	条件 1	条件 2	收缩性	前沿	Z3 验证
4pt 3.5pt	KAN (B-spline)	✓	✓	✓*	内部 [†]	512/512
	KAN (Chebyshev)	✓	✓	✓	内部	完整 [‡]
	KAN (Wavelet)	✓	✓	~	内部	完整 [‡]
	MLP + ReLU	✗	✗ [§]	N/A	外部	0/16
	MLP + SiLU/GELU	✗	✗ [¶]	N/A	外部	0/16 [#]
	MLP + Sigmoid	✗	✓	N/A	外部	–
	MLP + Tanh	✗	✓	N/A	外部	–
	Transformer	✗	✗	N/A	外部	N/A
	CNN (Conv2d)	✗	✗	N/A	外部	N/A

✓ = 满足；✗ = 违反；~ = 取决于小波基选择。

* 收缩性在训练 KAN 学生 [28, 16, 4] 上验证 (VRM-KD 蒸馏)；Tankman [20] 证明 $P(\text{KAN}) \leq 1$ 为结构性质。[†] B 样条 KAN 是本分类学中唯一在物理硬件上 (TIA Portal V21, S7-1200) 同时满足并经验验证所有三个条件的架构。[‡] ChebyKAN: 命题 2 形式验证；Z3 可验证率 496/512, 96.9% (E54)。[§] ReLU 为分段线性 (C^0)； f'' 在 $x = 0$ 处为 Dirac delta, de Boor 界不适用。[¶] SiLU 包含 e^{-x} , 在 Z3 NRA 理论中超越不可判定。[#] 经验确认: MLP [28, 16, 4] 含 SiLU, 0/16 组件 Z3 可验证 (E41)。

$$L_B^{\text{analytic}} \leq \frac{3}{h} \cdot \max_c |\Delta w_c|, \quad M_2^{\text{analytic}} \leq \frac{6}{h^2} \cdot \max_c |\Delta^2 w_c| \quad (10)$$

对 KAN 学生 [28, 16, 4], $G = 8$, $h = 0.75$: 解析界 $M_2^{\text{analytic}} \leq 12.8$; 经验值 $M_2 = 0.177$ (E11), 紧致 98.6%。解析界作为架构保证, 经验测量提供模型特定精炼。

条件 3 (收缩组合)。对训练后的 KAN: $L_B = 0.65$, $\|W^{(1)}\|_{1,\infty} \leq 0.28$, 乘积 $0.182 \ll 1$ 。Tankman [20] 证明对标准 KAN 操作集 $P(\text{KAN}) \leq 1$ 是结构性质。□

E. 标准 MLP 不接受紧致 SVNN 误差界

命题 1 (标准 MLP 不接受 SVNN 紧致界结构)。使用 ReLU、SiLU、Sigmoid 或 Tanh 激活的标准 MLP 不接受 SVNN 条件 2 的编译器可计算、架构无关的紧致 LUT 误差界。

证明。(a) *SiLU/GELU*: SiLU 包含超越函数 e^{-x} , Z3 的 NRA 理论不可判定。经验上 MLP [28, 16, 4] 含 SiLU 实现 0/16 Z3 可验证组件 (E41)。(b) *ReLU*: ReLU 在 $x = 0$ 处违反 C^2 连续性 (f'' 为 Dirac delta), de Boor 界不适用。(c) *Sigmoid/Tanh*: 满足条件 2 但违反条件 1——标准 MLP 层将仿射变换和逐点激活耦合在单一操作中。

MLP 可达到的最优误差界为:

$$\Delta_{\text{MLP}}^{(L)} \leq O(L \cdot L_{\text{act}}^L \cdot \|\mathbf{W}\|_{\text{prod}}) \quad (11)$$

超过 3–4 层即空洞。对比之下, KAN 界 $O(L \cdot M_{\text{max}} \cdot h^2 \cdot d_{\text{max}})$ 与权重幅度无关且随 LUT 分辨率以三次方减小。□

架构分类学。表 I 将主要神经架构族映射到 SVNN 条件, 揭示了鲜明分界: 分解为纯线性 + 逐元素操作且使用 C^2 参数可计算激活的架构位于内部。无论激活选择如何, 无一 MLP 变体跨越可编译前沿。

F. ChebyKAN 满足 SVNN 条件

命题 2 (ChebyKAN 是结构可验证的)。使用切比雪夫多项式基函数的 KAN 架构 (ChebyKAN) [39], 定义为

$$\phi_{j,i}(x) = \sum_{n=0}^N c_{j,i,n} \cdot T_n(\tanh(x)) \quad (12)$$

满足定理 2 的 SVNN 条件 1-2。ChebyKAN 通过多项式 NRA 享有 Z3 可验证性, 无需 B 样条基所需的分段枚举。

证明。

条件 1: ChebyKAN 层分解为三个纯操作: (1) $\tanh(x_i)$ (逐元素), (2) $T_n(u_i)$ (逐元素, Chebyshev 多项式), (3) 线性组合 $\sum c_{j,i,n} \cdot v_{i,n}$ 。无非线性-线性耦合。

条件 2: 通过 Markov 不等式 [40], 对 $[-1, 1]$ 上任意 N 次多项式 p :

$$\max_{y \in [-1, 1]} |p''(y)| \leq \frac{N^2(N^2 - 1)}{3} \cdot \max |p(y)| \quad (13)$$

对 $g(y) = \sum_n c_n T_n(y)$, 有 $\max |g(y)| \leq \sum_n |c_n|$ 。因此:

$$M_2^{\text{Cheby}}(g) \leq \frac{N^2(N^2 - 1)}{3} \cdot \sum_{n=0}^N |c_n| \quad (14)$$

通过链式法则组合 $\tanh$ 和 g , 最终 *a priori* 曲率界为:

$$M_2(f) \leq \frac{N^2(N^2 + 5)}{3} \cdot \sum_{n=0}^N |c_n| \quad (15)$$

Z3 可验证性: Chebyshev 多项式可直接表达为 y 的显式多项式 (如 $T_2(y) = 2y^2 - 1$, $T_3(y) = 4y^3 - 3y$), 属于 Z3 的 NRA 理论。经验验证: ChebyKAN[28, 16, 4], $N = 5$, 实现 496/512 Z3 可验证组件 (96.9%, E54)。Markov 基解析 M_2 界比经验 M_2 松 $5.4 \times$ (均值 8.5 vs. 45.6) ——解释 3.1% 不可验证组件。

与 MLP+Tanh 的对比。表 I 显示 MLP+Tanh 位于外部 (违反条件 1) 尽管使用了与 ChebyKAN 相同的 $\tanh$ 激活。这隔离了 SVNN 条件的结构性: 决定 SVNN 成员资格的不是激活函数本身, 而是架构如何分解该激活相对于线性变换。

与 B 样条 KAN 的比较。两种基代表紧致性-复杂度谱上的互补点: B 样条通过分段感知精炼实现更紧致的界 ($6.0 \times$), 但需 $O(G)$ 分段枚举; Chebyshev 通过 Markov 不等式实现单一全局界, $O(1)$ 计算, 无需分段枚举。两种方法都从参数单独产生可计算的界, 满足条件 2。□

注记 4 (Wavelet-KAN 和 Fourier-KAN)。命题 2 的证明技术自然扩展到其他正交多项式和紧支撑分段多项式小波基。表 I 中 Wavelet-KAN 标记为 “~” (取决于小波选择), 反映 SVNN 条件是基特定的。

G. 条件 1 的计算必要性

定理 5 (条件 1 的计算必要性)。设 $\mathcal{A}$ 为违反条件 1 的前馈架构——即某层将线性变换和非线性激活耦合在单一融合操作 $\mathbf{h} = \sigma(W\mathbf{x} + \mathbf{b})$ 中。则计算紧致逐输出编译器误差界 $\varepsilon^*(M, X) = \sup_{x \in X} \|M(x) - C(M)(x)\|_\infty$ 在神经元数上 **NP 难**。相比之下, 任何满足条件 1 的架构允许在 $O(L \cdot d_{\max}^2)$ 时间内通过定理 2 的结构归纳计算 ε^* 的界。

证明。步骤 1 (归约): 对违反条件 1 的架构, 紧致界等于 $\sup_x \|\sigma(Wx + b) - \tilde{\sigma}(Wx + b)\|_\infty$ ——关于输入和线性预激活的联合优化, 等价于神经元可达性问题。步骤 2 (NP 难度): Katz 等 [32] 证明神经网络验证的决策版本

对 ReLU 网络是 NP 完全的。由于紧致误差界计算需要在每层求解神经元可达性, ϵ^* 不可在多项式时间内计算 (除非 $P=NP$)。对比条件 1 满足架构: 结构归纳产生 $O(L \cdot d_{\max}^2)$ 时间的显式上界。□

注记 3 (分离结果解释). 定理 5 建立了 SVNN 与非 SVNN 架构之间的**计算复杂度分离**: 前者允许 $O(\text{poly}(L, d))$ 编译器计算误差界, 后者对紧致界需 NP 难计算。为非 SVNN 架构提供误差界的工具 (CROWN、 α - β -CROWN [41]、Marabou [33]) 仅通过接受过近似或指数最差代价实现。

H. SVNN 兼容架构的泛化界

定理 6 (SVNN 的泛化界). 设 M 为满足 SVNN 条件 1–3 的 KAN 架构, 收缩常数 $\gamma < 1$, 深度 L , 输入域 $X \subset [-B, B]^{d_{\text{in}}}$. 设 $\hat{M}$ 为 n 个 i.i.d. 训练样本上 ρ -Lipschitz 损失下的经验风险最小化器。则以至少 $1 - \delta$ 的概率:

$$L(\hat{M}) - \hat{L}(\hat{M}) \leq \frac{4\rho\gamma^L B}{\sqrt{n}} + 3\sqrt{\frac{\log(2/\delta)}{2n}} \quad (16)$$

关键项 $\gamma^L B/\sqrt{n}$ 随网络深度 L **指数衰减**——更深的 SVNN 网络泛化严格更优。

证明. 使用 Rademacher 复杂度框架 [42] 三步进行。步骤 1: 由条件 3, 全局 Lipschitz 常数为 $L_{\text{global}}(M) \leq \prod_{\ell}(L_f^{(\ell)} \cdot \|W^{(\ell+1)}\|_{1,\infty}) \leq \gamma^L$. 步骤 2: 由 Lipschitz 收缩不等式 [42], $\mathfrak{R}_n(\mathcal{F}_M) \leq \gamma^L \cdot B/\sqrt{n}$. 步骤 3: 应用标准泛化界 [43] 得到式 16. □

推论 1 (深度改善泛化). 在条件 3 下, 添加一层严格减小泛化差距。这与标准 MLP 理论预测相反 (添加层通常增加差距)。

对训练 KAN 学生的定量实例化。对 $[28, 16, 4]$, $\gamma = 0.182$, $L(\hat{M}) - \hat{L}(\hat{M}) \leq 0.0136$. 与标准 MLP 对比: $L_{\text{global}}^{\text{MLP}} \approx 3.8$, Rademacher 复杂度项约 0.217——比 KAN 的 0.0019 大一个数量级 (114× 差异)。

注记 4 (SVNN 六大定理). 六个定理和两个命题构成 SVNN 框架的完整理论架构:

- **定理 1 (§IV)**: 实例化——NeuroPLC 以可证明误差界编译特定 KAN。
- **定理 2 (§III-C)**: 充分性——条件 1–2 保证任意 SVNN 架构的设计时正确性。
- **定理 3 (§IV)**: DA 极小极大最优性。
- **定理 4 (§IV)**: L 层深度均匀界。
- **定理 5 (§III-G)**: 计算必要性——违反条件 1 为 NP 难。
- **定理 6 (§III-H)**: 学习理论推论——条件 3 产生深度改善泛化界。

命题: 命题 1 (标准 MLP 不满足)、命题 2 (ChebyKAN 满足)。

I. 对编译器设计的启示

SVNN 框架对面向安全关键嵌入式平台的神经网络编译器设计有五点启示: (1) 选择可验证架构而非试图验证任意架构输出; (2) 设计 IR 以反映架构分解; (3) 利用架构属性获取更紧致界; (4) 将正确性保证与实现分离; (5) 桥接设计时和机械化验证。这些启示将 NeuroPLC 定位为更广泛编译器设计范式——结构可验证编译——的首个实例。

IV. NEUROPLC: 编译器架构与训练流水线

A. 系统概览

从 PyTorch 模型生成经过认证的 PLC 代码需要的不仅仅是翻译——它需要一条从浮点权重到定点 SCL 算术的可验证链路。NeuroPLC 流水线围绕这一需求组织, 而非方便性: 其五个阶段的每一个消除一种特定的正确性威胁。阶段 1 (28-D 特征提取) 界定输入域至 $[-3, 3]^{28}$ ——所有下游保证的前提条件。阶段 2 (带自注意力的 1D-CNN 教师模型) 建立 KAN 必须匹配的准确率上限。阶段 3 (VRM 知识蒸馏) 将此上限传递到架构满足




图 1. NeuroPLC 端到端流水线。(1) 28-D 特征提取；(2) 教师 1D-CNN 训练；(3) VRM-KD 蒸馏到 KAN 学生；(4) 基于 IR 的 SCL 编译；(5) TIA Portal 验证。

SVNN 条件的紧凑 KAN 学生——此步骤是架构上不可协商的：它产生编译器能够认证的唯一模型类型。阶段 4（基于 IR 的编译）是编译器核心。阶段 5（TIA Portal V21 自动化验证）提供硬件级编译证据（0e 0w）。编译器独立于具体的故障诊断应用运行——它接受任何满足 SVNN 的模型并为任何受支持的 PLC 目标生成经过认证的 SCL。图 1 展示流水线。

B. 编译器架构

NeuroPLC 编译器（图 2）实现传统四阶段设计：前端（Frontend）、IR 图、优化器（Optimizer）和后端（Backend）。该架构将模型表示与代码生成清晰分离，支持多模型和多目标。

1) IR 图：中间表示（IR）是一个有向无环图，每个节点代表六种操作类型之一：MatMul、BsplineLUT、StandardAct、Softmax、Argmax 和 Add。节点携带类型化属性并通过显式端口边连接。图支持拓扑排序、环检测、可达性分析和 JSON 序列化。

引理 1（IR 极小性）。 6 操作 IR 类型集 $\mathcal{O} = \{\text{MatMul}, \text{BsplineLUT}, \text{StandardAct}, \text{Add}, \text{Softmax}, \text{Argmax}\}$ 对于 SVNN 条件 1-2（定理 2）下任意 KAN 分类器既是必要的也是充分的，且为保持这些条件的极大集合。

证明概要。 **必要性：** 移除 $\mathcal{O}$ 中任意 o 会破坏 KAN 表达能力。MatMul 是唯一跨输入维度加权求和操作；BsplineLUT 是唯一携带可证明 LUT 误差界的操作（ $\varepsilon \leq M_2 h^2 / 8$ ），无此则定理 1 的保证坍塌；StandardAct 处理无需近似的精确闭式激活（SiLU）；Add 合并 KAN 双路径（基 + 样条）输出；Softmax 和 Argmax 分别产生归一化概率和离散决策。**充分性：** 构造性编译算法处理每 KAN 层：发出 StandardAct(SiLU) $\rightarrow$ MatMul(base) $\rightarrow$ BsplineLUT(spline edges) $\rightarrow$ MatMul(spline) $\rightarrow$ Add(merge)，然后对分类器头发射 Softmax $\rightarrow$ Argmax。每步恰好映射到 $\mathcal{O}$ 中一种操作类型；结果图无环（前馈拓扑）。**极大性：** 添加更多类型（Conv、BatchNorm、Dropout）会违反一个或多个 SVNN 条件——Conv 将空间混合与线性操作耦合（违反条件 1），BatchNorm 引入运行时依赖统计量（违反条件 2 的参数可计算性要求），Dropout 引入与确定性最差情况界不兼容的随机性。消融研究（表 II）经验证实 BsplineLUT 不可替代：移除它导致 47.4x 的 IR 节点数爆炸。 ■

经验验证：IR 设计消融。 为量化每种 IR 操作类型的价值，我们在 KAN [28, 16, 4] 上进行消融研究：对三种非平凡操作类型（BsplineLUT、Add、StandardAct），模拟其移除——将该类型所有操作展开为剩余原语——并测量对 IR 节点数、内存和计算操作的影响。所有消融变体均从完整 IR 分析构造而得，无需单独模型训练或重编译，确保在相同模型权重下隔离每种操作类型的结构贡献。

结果（表 II）确认 BsplineLUT 是不可替代的操作：移除它强制 $28 \times 16 + 16 \times 4 = 512$ 个学习 B 样条激活函数各自独立物化，IR 节点数从 11 爆炸至 521（47.4x）。内存和操作分别增加 1.9x 和 1.7x，几何平均开销




图 2. 编译器架构。前端 (PyTorch → IR) → IR 图 (6 种操作类型) → 优化器 → 后端 (S7-1200/S7-1500 SCL 代码生成) → 验证。

4.3×。相比之下，Add 和 StandardAct 可以微小开销 ($\leq 1.1\times$) 模拟，确认 6 操作集恰好包含正确的抽象层次：BsplineLUT 封装了通用 ML 编译器无法优化的 KAN 特定计算。

2) 前端：前端将训练后的 PyTorch 模型转换为 IR 图。对 KAN 模型，每个 KANLinear 层分解为三个 IR 路径：(a) 基分量的 SiLU 激活 → MatMul(base_weight)，(b) 带预计算 (out_dim, in_dim, N_lut) 查表的 BsplineLUT 节点用于 B 样条分量，(c) 合并两条路径的 Add 节点。对 MLP 模型，每个 nn.Linear 层成为 MatMul 节点，隐藏层之间插入 StandardAct(ReLU) 节点。

3) 编译器后端：后端按拓扑序遍历优化后的 IR 图并发出 IEC 61131-3 SCL 代码。所有参数存储在单一数据块 (DB200, NeuroPLC_Weights) 中作为扁平 REAL 数组，启用优化访问。推理功能块 (FB1) 通过显式点积累加实现矩阵-向量乘法，通过 case 级 IF/ELSE 实现激活函数，通过专用查表函数 (FC2, BsplineEval) 实现 B 样条评估，该函数执行二分搜索 + 线性插值 (算法 1)。提供两个具体后端：S7-1200 (50 KB 工作内存预算，紧凑 FOR 循环模式，15 点 LUT) 和 S7-1500 (1.5 MB 预算，展开性能模式，50 点 LUT)。

4) 自适应 B 样条采样：优化器阶段引入曲率感知自适应采样传递。曲率驱动节点放置是几何建模中的标准技术 [44]；我们将此技术应用于神经网络激活 LUT 设计。给定高密度预采样的 B 样条激活函数 (每函数 100 点)，计算 1-D 函数图的平面曲率 $\kappa(x) = |\phi''(x)|/(1 + \phi'(x)^2)^{3/2}$ ，跨所有 (输出, 输入) 对。累积曲率 $C(x) = \int \kappa(t)dt$ 归一化到 $[0, 1]$ ，目标采样点均匀放置于 $C(x)$ 空间后通过逆插值映射回 x 空间。这使采样点集中于高曲率区域，同时保持 $O(\log N)$ 二分搜索用于查表。对 C^2 函数的分段线性插值误差界为 $\epsilon_{\text{LUT}} \leq M_2 \Delta^2/8$ [37], [45]，其中 $M_2 = \max |\phi''(x)|$ (跨 512 个 B 样条函数中位数: 0.177, 逐函数最大值: 1.586; 测量协议见 E11, 对抗最差情况分析见命题 2)， Δ 为最大网格间距。在 $N = 15$ 点 ($\Delta \approx 0.43$ 于 $[-3, 3]$) 处， $\epsilon_{\text{LUT}} \leq 0.0041$ 每激活——远低于正确分类样本的最小类间对数边界 (1.35, E6)。

E4 实验 (§V) 识别出 ~ 18 格点的经验交叉点：低于此密度自适应采样优于均匀 (10 点处 +11.6%，15 点

Algorithm 1 B 样条查表评估 (SCL: FC2)

```

1: 输入:  $x \in \mathbb{R}$ , grid  $\mathbf{G}[0..N-1]$ , table  $\mathbf{T}[0..N-1]$ 
2: 输出:  $\phi(x)$ 
3:  $lo \leftarrow 0, hi \leftarrow N-1$ 
4: while  $hi - lo > 1$  do
5:    $mid \leftarrow lo + (hi - lo)/2$ 
6:   if  $x > \mathbf{G}[mid]$  then  $lo \leftarrow mid$ 
7:   else  $hi \leftarrow mid$ 
8:   end if
9: end while
10:  $t \leftarrow (x - \mathbf{G}[lo]) / (\mathbf{G}[hi] - \mathbf{G}[lo])$ 
11: return  $\mathbf{T}[lo] \cdot (1.0 - t) + \mathbf{T}[hi] \cdot t$ 

```


B-Spline LUT: Uniform vs Curvature-Adaptive Sampling

图 3. 等存储预算下均匀 vs. 曲率感知自适应 B 样条 LUT 采样对比 (15 和 50 格点)。自适应采样将点集中于高曲率区域, 降低 L2 近似误差。

处 +4.9%); 高于此均匀实现更低 L2 误差 (50 点处 -34.0%)。优化器因此提供 `auto_bspline` 传递, 阈值选择策略, 使编译器的 LUT 离散化数据驱动 (图 3)。

5) *DP 最优 LUT 放置*: 以上曲率自适应启发式经验有效但不提供最优性保证。我们因此形式化 LUT 节点放置问题:

给定函数 $\phi(x)$ 在 $[a, b]$ 上 M 个高分辨率点 $\{x_m\}_{m=0}^{M-1}$ 处采样, 选择包含 a 和 b 的 K 个点, 以最小化跨所有 $K-1$ 段的最大分段线性插值误差。

这是经典 DAG 最短路径问题。定义段代价 $c(j, i) = \max_{x \in [x_j, x_i]} |\phi(x) - L_{j,i}(x)|$, 其中 $L_{j,i}$ 是 (x_j, ϕ_j) 和 (x_i, ϕ_i) 间的线性插值。de Boor 界给出 $c(j, i) \leq \frac{1}{8} \max_{[x_j, x_i]} |\phi''| \cdot (x_i - x_j)^2$ 。DP 递推为:

$$dp[i][k] = \min_{j: k-2 \leq j < i} \max(dp[j][k-1], c(j, i)) \quad (17)$$

其中 $dp[i][k]$ 是使用 k 个点覆盖 $[x_0, x_i]$ 的最小可达最大误差, 第 k 个点位于 x_i 。基例: $dp[i][2] = c(0, i)$ 。解 $dp[M-1][K]$ 及其回溯指针在 $O(M^2 K)$ 时间内产生最优 K 点放置。对 $M = 200$, $K \in [10, 50]$, DP 在 CPU 上 ~ 20 ms 完成。

表 II

IR 设计消融：从 6 操作 IR 中移除每种操作类型的影响。移除 BSPLINE LUT 强制 512 个独立样条函数被物化为单独节点，导致节点数爆炸 47.4×。

IR 变体	操作数	节点数	内存	FLOPs	开销
完整 IR (6 ops)	6	11	35.2 KB	7,028	1.0×
无 BsplineLUT	5	521	65.2 KB	12,148	4.3×
无 Add	5	15	35.4 KB	7,124	1.1×
无 StandardAct	5	9	35.8 KB	7,868	1.0×

Algorithm 2 贪心自适应 LUT 密度分配

```

1: 输入: 每函数  $M_2[\phi]$ , 预算  $B$ ,  $N_{\min} = 3$ 
2: 输出: 每函数分配  $N[\phi]$ 
3:  $N[\phi] \leftarrow 3$  for all  $\phi$ ; 计算  $\varepsilon[\phi] = M_2[\phi] \cdot (b - a)^2 / [8(N[\phi] - 1)^2]$ 
4:  $S \leftarrow 4 \cdot \sum N[\phi]$ 
5: while  $S + 4 \leq B$  do
6:    $\phi^* \leftarrow \arg \max_{\phi} \varepsilon[\phi]$ 
7:    $N[\phi^*] \leftarrow N[\phi^*] + 1$ ;  $S \leftarrow S + 4$ 
8:    $\varepsilon[\phi^*] \leftarrow M_2[\phi^*] \cdot (b - a)^2 / [8(N[\phi^*] - 1)^2]$ 
9: end while
10: return  $N[\phi]$ 

```

所有 512 个学习 B 样条的平均激活函数用作优化目标，所有函数共享结果最优网格以保证二分搜索兼容性。在 E4 (§V) 中，我们比较全部三种策略（均匀、曲率自适应、DP 最优），发现曲率启发式以 DP 计算成本的 0.2–0.4% 达到 DP 最优误差减少的 93.2–96.5%。

6) 编译器优化流水线：除 LUT 离散化外，NeuroPLC 提供三项实质性优化传递，针对 PLC 执行效率：

算子融合 (*FuseMatMulAdd*)。KAN 层计算 $y_j = \sum_i W_{j,i} \cdot \text{SiLU}(x_i) + \sum_i \phi_{j,i}(x_i)$ ，其中 IR 表示为 $\text{MatMul} \rightarrow \text{Add}(\text{spline_sum})$ 。融合传递消除中间 MatMul 输出数组，每 KAN 层节省 $d_{\text{out}} \times 4$ 字节，并移除一次完整数组写入遍历。

循环不变量外提 (*HoistBinarySearch*)。朴素发射中，B 样条 LUT 评估对每对（输出，输入）执行二分搜索——对 KAN [28, 16, 4] 为 $16 \times 28 + 4 \times 16 = 512$ 次每推理。由于输入 x_i 在所有输出维度上相同，二分搜索结果（区间索引 lo 、 hi 和插值分数 t ）仅依赖输入索引 i ，而非输出索引 o 。外提将二分搜索移至外层输入循环，将次数减少至 $28 + 16 = 44$ 每推理——11.6× 减少。

更一般地，对任意 L 层 KAN 架构 $[d_0, d_1, \dots, d_L]$ ：

$$N_{\text{naive}} = \sum_{\ell=1}^L d_{\ell} \cdot d_{\ell-1}, \quad N_{\text{hoisted}} = \sum_{\ell=1}^L d_{\ell-1}, \quad (18)$$

$$R = \frac{\sum_{\ell=1}^L d_{\ell} d_{\ell-1}}{\sum_{\ell=1}^L d_{\ell-1}} \quad (19)$$

减少比 R 随架构深度和宽度增长（如 $R = 11.6\times$ 对 [28, 16, 4]， $R = 19.4\times$ 对 [28, 32, 16, 4]）——外提对更大的 KAN 架构更有益，提供有利的扩展行为。算子融合的内存节省类似参数化：每融合 $\text{MatMul} + \text{Add}$ 消除 $d_{\ell} \times 4$ 字节中间存储每 KAN 层，总节省 $4 \cdot \sum_{\ell=1}^L d_{\ell}$ 字节。

强度削减 ($\text{EXP} \rightarrow \text{LUT}$)。西门子 S7-1200 无硬件 EXP 指令；通过 Taylor 级数的软件 EXP 每次调用 ~50–100 REAL 操作。KAN 前向传递每推理需要 48 次 EXP 调用（28 SiLU + 16 SiLU + 4 Softmax），消耗估

计 15–30% 推理时间。`lutize_exp` 传递以 64 点查表替代这些调用，复用与 B 样条 LUT 相同的二分搜索基础设施。

7) 优化传递正确性：虽然以上优化传递通过端到端测试经验验证，但正确性关键的 PLC 部署要求形式保证——无优化引入静默错误。我们为三个核心传递提供半形式正确性证明，确立每次变换是观察等价的——优化 SCL 代码对操作域 $[-3, 3]^{d_o}$ 内所有输入产生与未优化代码相同的分类结果。

正确性框架。每个证明遵循结构：(i) 前提——传递前 IR 必须满足的条件；(ii) 变换——传递对 IR 或发射代码的操作；(iii) 正确性声明——变换后程序保持语义；(iv) 证明概要——基于 S7-1200 语义的半形式论证。

a) *HoistBinarySearch* (循环不变量外提)。：二分搜索纯性。函数 $BS(\mathbf{g}, x)$ 在排序网格 $\mathbf{g} \in \mathbb{R}^K$ 上返回区间索引 (lo, hi) 和插值分数 t ，满足 $g_{lo} \leq x < g_{hi}$ 且 $t = (x - g_{lo}) / (g_{hi} - g_{lo})$ 。它仅读取 $\mathbf{g}$ (常量 DB 数组) 和 x (局部变量)，不写入内存。在 S7-1200 上，所有内存访问通过命名 DB 偏移且无别名，BS 是纯函数——其结果仅依赖其参数。

命题 3 (*HoistBinarySearch* 正确性)。对任意 *BsplineLUT* 节点，外提代码 (每输入一次二分搜索，跨输出复用) 与朴素代码 (每输出-输入对二分搜索) 产生相同数值结果。

证明概要。朴素嵌套循环发射对每 $o \in [0, d_{out})$ 和 $i \in [0, d_{in})$ 计算 $(lo, hi, t) = BS(\mathbf{g}, x_i)$ 后累加到 $y[o]$ 。外提发射交换循环：对每 i 计算一次 (lo, hi, t) ，然后累加到所有 $y[\cdot]$ 。

由以上纯性论证， $BS(\mathbf{g}, x_i)$ 是纯函数，其结果仅依赖 x_i ，而 x_i 在内层 (输出) 循环中为常量。循环交换有效，因累加 $y[o] += \text{interp}(\mathbf{T}_{o,i}, lo, hi, t)$ 无跨迭代依赖——每 $y[o]$ 仅被累加，在所有循环完成前从未被读取。由于 S7-1200 上 REAL 加法为 IEEE 754 float32 且严格从左到右求值 (无并行重排)，和相同。对架构 $[d_0, \dots, d_L]$ ，二分搜索次数从 $\sum_{\ell=1}^L d_\ell d_{\ell-1}$ 降至 $\sum_{\ell=1}^L d_{\ell-1}$ 。□

b) *FuseMatMulAdd* (算子融合)。：

命题 4 (*FuseMatMulAdd* 正确性)。当 IR 包含一个 *MatMul* 节点，其输出仅馈入一个 *Add* 节点 (规范 KAN 分解)，消除中间数组 $v_{mm}[\cdot]$ 并在 *Add* 处内联其计算产生相同结果。

证明概要。KAN 前向传递定义每输出为 $y_j = \alpha \cdot \sum_i W_{j,i} \text{SiLU}(x_i) + \beta \cdot \sum_i \phi_{j,i}(x_i)$ 。IR 将第一项表示为 *MatMul*→*Add*。由 IR 图构造，单消费者性质成立：在规范 KAN 分解中，基路径和样条路径恰好在一个 *Add* 节点合并；无其他节点引用 *MatMul* 输出。内联代入替换“ $v_j := E_j$; $y_j := f(v_j, \dots)$ ”为“ $y_j := f(E_j, \dots)$ ”。由操作语义，对纯表达式 E 和单次使用变量 v ： $\llbracket v := E; y := f(v) \rrbracket \rho = \llbracket y := f(E) \rrbracket \rho$ 。S7-1200 无融合乘加改变舍入，无乱序执行重排操作。内联代码因此计算与两步版本相同的 float32 值。内存节省： $4 \cdot \sum_{\ell=1}^L d_\ell$ 字节 (每层消除一个 REAL 数组)。□

c) *LUTizeEXP* (强度削减)。：

命题 5 (*LUTizeEXP* 正确性)。以 N 点线性插值 LUT 替代解析 *EXP/SiLU* 引入误差界为 $\varepsilon_{\text{SiLU}} \leq M_2^{\text{SiLU}} \Delta^2 / 8$ 和 $\varepsilon_{\text{EXP}} \leq M_2^{\text{EXP}} \Delta^2 / 8$ ，其中 $\Delta = 10 / (N - 1)$ 为网格间距， $M_2^{\text{SiLU}} \approx 1.1$ ， $M_2^{\text{EXP}} = e^5 \approx 148.4$ 于域 $[-5, 5]$ 。只要累积误差不超过最小类间对数边界，分类即保持。

证明概要。标准分段线性插值误差界对 $[a, b]$ 上任意 C^2 函数 f ，均匀网格间距 Δ 为： $\max_x |f(x) - \hat{f}_{\text{LUT}}(x)| \leq M_2 \Delta^2 / 8$ ，其中 $M_2 = \max_{x \in [a, b]} |f''(x)|$ [46]。

对 SiLU 于 $[-5, 5]$ ： $|\text{SiLU}''(x)| \leq 1.1$ (解析，最大值出现在 $x = 0$ 附近)。以 $N = 64$ ， $\Delta = 10 / 63 \approx 0.1587$ ，给出 $\varepsilon_{\text{SiLU}} \leq 0.00346$ 。2,000 测试点经验测量产生 $\max |\text{error}| = 0.00157$ ，与界一致。

对 EXP 于 $[-5, 5]$ ： $\max |\text{EXP}''(x)| = e^5 \approx 148.4$ ，给出 $\varepsilon_{\text{EXP}} \leq 0.467$ 。EXP LUT 仅用于 Softmax 归一化。以 $\exp(x_j) + \delta_j$ ($|\delta_j| \leq \varepsilon_{\text{EXP}}$) 替换 $\exp(x_j)$ ，对 4 类 Softmax 且输入在 $[-5, 5]$ 内，扰动每 softmax 输出至多 $2N\varepsilon_{\text{EXP}} / S_{\min} \approx 0.0037$ ，远低于经验最小分类边界 1.35 (式 22)。argmax 因此保持。

表 III
优化传递正确性总结

传递	声明数	状态	观测	保证
HoistBinarySearch	3	已证明	相同	搜索次数减少 $11.6\times$
FuseMatMulAdd	3	已证明	$\leq 1.9\times 10^{-6}$	节省 80 字节/层
LUTizeEXP	3	已证明	$\leq$ 解析界	边界 $\gg$ 累积误差
总计	9	全部正确	等价变换, 观察等价性保持	

全部三种 LUT 近似 (B 样条、SiLU、EXP) 的累积效应由定理 1 界定 ($\Delta \leq 0.172$), 安全因子 $3.9\times$ (边界/ (2Δ)) 确保分类正确性维持。□

表 III 总结各优化传递的正确性状态。跨三个传递全部 9 项声明均已证明正确, 确认编译器优化保持观察等价性。

8) 区间算术可证明正确性界: 设 $\varepsilon = M_2\Delta^2/8$ 为每激活 LUT 误差界。对 2 层 KAN:

$$\Delta y_j^{(0)} \leq \varepsilon \cdot \|W_{j,:}^{(0)}\|_1 \quad (20)$$

$$\Delta z_k \leq (\varepsilon + L_B \cdot \max_j \Delta y_j^{(0)}) \cdot \|W_{k,:}^{(1)}\|_1 \quad (21)$$

以模型特定 $M_2 = 0.177$ (E11 经验校准), 在 15 LUT 点的最差对数扰动:

$$\Delta z_{\max} \leq 0.172 \ll 1.35 = \min_{i \neq \hat{y}} (\text{logit}_{\hat{y}} - \text{logit}_i) \quad (22)$$

安全因子 $1.35/(2 \times 0.172) \approx 3.9\times$ ——分类正确性从数学上保证, 而非仅经验观察。

9) 符号结构仿射算术: 通过相关性跟踪实现更紧致界: 以上区间算术分析虽可靠, 但是保守的: 它将每激活 LUT 误差视为独立区间变量, 丢弃了权重矩阵的符号结构。这导致包裹效应——跨层复合的区间过估计。对 2 层 KAN, 过估计 $\sim 5\text{--}20\times$; 对更深网络呈指数增长 [47]。

我们应用符号结构仿射算术——称为双元算术 (DA), 遵循 Krukowski 等 [47]——Stolfi 和 de Figueiredo 仿射算术 [48] 在编译 NN 验证中的新型应用。DA 将每个变量表示为仿射形式 $x = x_0 + x_1\varepsilon$, 其中 $\varepsilon \in [-1, 1]$ 是编码 LUT 误差源的噪声符号。与区间算术不同, DA 保留了线性组合的符号结构。

考虑层 1 的输出对数 z_k 。在区间算术中:

$$|\Delta z_k|_{\text{IA}} \leq (\varepsilon + L_B \cdot \varepsilon \cdot \max_j \|W_{j,:}^{(0)}\|_1) \cdot \|W_{k,:}^{(1)}\|_1 \quad (23)$$

在双元算术中, 传播误差 $\Delta y_j^{(0)} = \varepsilon \sum_i W_{j,i}^{(0)} \cdot \text{sign}(\delta_i)$ 保留其带符号结构。经过 B 样条 (Lipschitz 界 L_B) 再经 $W^{(1)}$:

$$|\Delta z_k|_{\text{DA}} \leq \varepsilon \cdot \left| \sum_j W_{k,j}^{(1)} \right| + \varepsilon \cdot L_B \cdot \sum_i \left| \sum_j W_{k,j}^{(1)} W_{j,i}^{(0)} \right| \quad (24)$$

式 24 中的关键项是嵌套和 $\sum_i |\sum_j W_{k,j}^{(1)} W_{j,i}^{(0)}|$: 正负权重路径在取绝对值前抵消, 而区间算术对每项分别取绝对值。对训练 KAN 模型, DA 界产生最差情况对数扰动 0.079 vs. IA 的 0.172——紧致 $2.2\times$ 。安全因子相应从 $3.9\times$ 提高到 $8.5\times$ 。

为什么 $3.1\times$? 符号结构解释。紧致比 $R = \|\Delta z_k\|_{\text{IA}} / \|\Delta z_k\|_{\text{DA}}$ 不是经验巧合——它来自训练 KAN 权重矩阵的符号分布。考虑组合系数 $C_{k,i} = \sum_j W_{k,j}^{(1)} \cdot W_{j,i}^{(0)}$ 。区间算术将其对误差的贡献界为 $\sum_j |W_{k,j}^{(1)}| \cdot |W_{j,i}^{(0)}|$ (全部 16 项相加)。双元算术则计算净带符号和 $|\sum_j W_{k,j}^{(1)} \cdot W_{j,i}^{(0)}|$, 允许正负项抵消。

对独立零均值权重条目 (随机初始化网络的一个合理零假设), 期望比遵循随机游走缩放:

$$R_{\text{expected}} = \frac{\mathbb{E}[\sum_j |W_{k,j}^{(1)}| \cdot |W_{j,i}^{(0)}|]}{\mathbb{E}[\sum_j W_{k,j}^{(1)} \cdot W_{j,i}^{(0)}]} \propto \sqrt{d_1} \approx 4.0 \quad (25)$$

表 IV

DA/IA 紧致比 $\propto \sqrt{d}$: 跨 105 个随机 KAN 架构 [28, d , 4] 的经验验证。PEARSON $r = 0.987$ 确认引理 3 预测的缩放律。

d (隐藏)	$\sqrt{d}$	均值比	标准差	范围
4	2.00	2.17×	± 0.40	[1.6, 2.8]
8	2.83	2.70×	± 0.44	[2.0, 3.5]
12	3.46	3.39×	± 0.40	[2.7, 4.3]
16	4.00	4.22×	± 0.55	[3.3, 5.5]
20	4.47	4.30×	± 0.54	[3.3, 5.2]
24	4.90	4.92×	± 0.76	[3.5, 6.5]
32	5.66	5.22×	± 0.52	[4.3, 6.4]

每维 15 个随机种子。训练 KAN [28, 16, 4]: $3.1 \times (d=16 \text{ 的 } 23 \text{ 百分位})$ 。最佳拟合: $\text{ratio} = 0.896\sqrt{d} + 0.349$ 。

其中 $d_1 = 16$ 为隐藏维数, $\sqrt{d_1}$ 因子来自对对称随机符号 $|\sum_{j=1}^{d_1} \pm 1| \sim \sqrt{d_1}$ 。

训练 KAN 权重展示近平衡符号—— $W^{(0)}$: 229 正 vs. 219 负 (共 448 条目); $W^{(1)}$: 33 正 vs. 31 负 (共 64)——验证了随机符号模型的适用性。测量值 $R = 3.1 \times$ 略低于随机符号预测 $\sqrt{16} = 4.0$, 因为训练诱导了部分符号一致性: 每 $W^{(0)}$ 行内, 占优符号占据 54–61% 条目, 减少了有效独立符号翻转数及抵消幅度。表 V 总结符号统计。

引理 3 (DA 概率紧致保证)。设 $W^{(0)} \in \mathbb{R}^{d_1 \times d_0}$ 和 $W^{(1)} \in \mathbb{R}^{d_2 \times d_1}$ 为 KAN 层 1 和 2 的权重矩阵。假设每个权重独立地从对称分布抽取 ($\mathbb{P}(W > 0) = \mathbb{P}(W < 0) = 1/2$), 且所有权重幅值有界: $w_{\min}^2 \leq |W_{k,j}^{(1)} \cdot W_{j,i}^{(0)}| \leq w_{\max}^2$ 对所有 (k, j, i) 。定义组合系数 $C_{k,i} = \sum_{j=1}^{d_1} W_{k,j}^{(1)} \cdot W_{j,i}^{(0)}$, DA 误差项 $E_{\text{DA}} = \sum_{i=1}^{d_0} |C_{k,i}|$, IA 误差项 $E_{\text{IA}} = \sum_{i=1}^{d_0} \sum_{j=1}^{d_1} |W_{k,j}^{(1)} \cdot W_{j,i}^{(0)}|$ 。

则对任意 $\delta \in (0, 1)$, 以至少 $1 - \delta$ 的概率:

$$R \equiv \frac{E_{\text{IA}}}{E_{\text{DA}}} \geq \frac{w_{\min}^2}{w_{\max}^2} \cdot \frac{\sqrt{d_1}}{\sqrt{2 \log(2d_0/\delta)} + 1/\sqrt{d_1}} \quad (26)$$

特别地, 对 $d_1 = 16$, $d_0 = 28$, $\delta = 0.05$, 且 $w_{\min}^2/w_{\max}^2 \geq 0.6$ (带权重衰减 KAN 的典型值): $R \geq 2.2$ 以 95% 置信度。训练 KAN 的经验 $R = 3.1 \times$ 超过此保守下界。

证明。对固定输出神经元 k 和输入维数 i , 令 $S_{k,i} = \sum_{j=1}^{d_1} s_{j,i}^{(k)}$ 其中 $s_{j,i}^{(k)} = \text{sign}(W_{k,j}^{(1)} \cdot W_{j,i}^{(0)}) \in \{\pm 1\}$ 。在对称分布假设下, 每个 $s_{j,i}^{(k)}$ 是独立 Rademacher 随机变量。由 **Hoeffding 不等式**: $\mathbb{P}(|S_{k,i}| \geq t) \leq 2 \exp(-t^2/2d_1)$ 。设 $t = \sqrt{2d_1 \log(2d_0/\delta)}$ 并对所有 d_0 个输入维数应用联合界, 得 $\mathbb{P}(\exists i: |S_{k,i}| \geq t) \leq d_0 \cdot 2e^{-t^2/(2d_1)} = \delta$ 。因此以概率 $\geq 1 - \delta$, 对所有 i : $|S_{k,i}| < \sqrt{2d_1 \log(2d_0/\delta)}$ 。结合 $E_{\text{IA}} \geq d_0 d_1 w_{\min}^2$ 和 $E_{\text{DA}} < d_0 w_{\max}^2 (\sqrt{2d_1 \log(2d_0/\delta)} + 1)$, 产生式 26。该引理确立了某种紧致是概率保证的; 经验幅值分布将此放大到测量值 $3.1 \times$ 。■

DA/IA 比值分布分析。为排除 $3.1 \times$ 紧致是单检查点择优结果的可能性, 我们分析跨 30 个独立实例化 KAN 架构 (相同结构 [28, 16, 4], 不同随机初始化, 种子 0–29) 的 DA/IA 比分布。比值遵循良好分布: 均值 3.71, 标准差 0.81, 范围 [2.11, 5.11], 训练模型比值 (3.1) 落在 23 百分位——略低于均值但在一标准差内。

跨 105 随机架构的缩放律验证。为验证 $\sqrt{d_1}$ 缩放是结构定律而非经验巧合, 我们测量跨 105 个随机实例化 2 层 KAN 架构 (7 个隐藏维数 $d_1 \in \{4, 8, 12, 16, 20, 24, 32\}$, 每维 15 个随机种子) 的 DA/IA 紧致比 (表 IV)。均值紧致比与 $\sqrt{d_1}$ 的 Pearson 相关系数为 $r = 0.987$ ($p = 3.6 \times 10^{-5}$), 最佳拟合线 $\text{ratio} = 0.896\sqrt{d_1} + 0.349$ 。斜率 0.896 接近式 25 的理论预测 1.0, 确认随机游走机制。这确立了 $\sqrt{d_1}$ 缩放律为预测未见 KAN 架构 DA 收益提供了预测工具。

表 V
训练 KAN 权重符号结构 (DA 紧致分析)

矩阵	形状	正	负	占优/行
$W^{(0)}$ (L0)	16×28	229 (51%)	219 (49%)	54-61%
$W^{(1)}$ (L1)	4×16	33 (52%)	31 (48%)	—
分析	值	来源		
R_{rand} (理论)	$\sqrt{16}=4.0$	式 25		
R_{emp} (DA)	3.1	E9, 完整流水线		
R_{base} (无样条)	2.2	仅基路径		

3.1× 紧致包含 B 样条传播。2.2× 仅基路径隔离符号抵消。每行占优符号: 低 → 更平衡
→ 更大 DA 收益。

表 VI
分段感知 vs. 全局 de Boor 界 (N=15 LUT 点)

指标	N=10	N=15	N=20	N=50
全局 ε (de Boor)	0.00998	0.00412	0.00224	0.00034
逐段 ε (均值)	0.00179	0.00069	0.00036	0.00005
紧致比 (全局/均值)	5.6×	6.0×	6.2×	6.7×
$\varepsilon_j < 0.5\varepsilon$ 段	96.2%	96.7%	97.0%	97.4%
$\varepsilon_j < 0.2\varepsilon$ 段	63.5%	67.6%	69.2%	72.3%
DA 分段感知改进	1.4×	1.4×	1.4×	1.4×

逐段 ε 值平均紧致 6.0×, 使能与 DA 加性组合的输入依赖验证。

10) 分段感知 de Boor 界: 全局 de Boor 界 (§IV) 使用跨整个输入域 $M_2 = \max_{x \in [a,b]} |\phi''(x)|$ 计算单个全局 $\varepsilon_{\text{LUT}} = M_2 \Delta^2 / 8$, 这是最差情况二阶导数。这是保守的: B 样条函数可能在域边界附近 ($|x| \approx 3$) 展示高曲率, 而在内部 ($|x| \approx 0$) 几乎线性。全局 M_2 以最差情况惩罚所有 LUT 段。

我们通过利用三次 B 样条二阶导数的分段线性结构进行精炼。对 $\phi(x) = \sum_c w_c B_{c,3}(x)$, 二阶导数 $\phi''(x)$ 是分段线性的, 断点在 B 样条节点处。在无内部节点的任何区间上——特别是在每个 LUT 段 $[g_j, g_{j+1}]$ 上——最大值 $|\phi''|$ 出现在端点。这产生逐段界:

$$\varepsilon_j = \frac{M_{2,j} \cdot \Delta_j^2}{8}, \quad M_{2,j} = \max_{x \in [g_j, g_{j+1}]} |\phi''(x)| \quad (27)$$

对输入 x 落在 LUT 段 j 中, LUT 近似误差由 ε_j 而非全局 ε 界定。跨所有 512 个 B 样条激活函数和 $N = 15$ LUT 点, 逐段 ε_j 值平均比全局 ε 紧致 6.0× (均值 0.00069 vs. 0.00412)。关键地, 96.7% 的段有 $\varepsilon_j < 0.5\varepsilon_{\text{global}}$, 67.6% 有 $\varepsilon_j < 0.2\varepsilon_{\text{global}}$ 。

与符号结构仿射算术的组合。分段感知界与 DA 自然组合 (§IV-B9)。在 DA 误差传播 (式 24) 中, 全局 ε 替换为由特征维数 i 落入的 LUT 段导出的每输入 ε_i 值。每输入 ε_i 取共享输入 i 的所有输出维数中最大逐段 ε (保守, 保持可靠性)。这在 DA 对 IA 的 2.2× 改进之上额外紧致 1.4× (与 $\sqrt{d}$ 随机权重基线相比达 3.1×, §IV-B9)。组合界——带分段感知 LUT 误差的符号结构仿射算术——在 $N = 15$ LUT 点处达到安全因子约 $8.5 \times 1.4 \approx 11.9 \times$ (cf. 单独 IA 的 3.9×), 为编译 KAN 推理提供迄今最强形式保证。

11) 自适应混合精度 LUT 分配: 所有先前的 B 样条 LUT 离散化方法——均匀、曲率自适应和 DP 最优——将相同点数 N 分配给每个激活函数。这是次优的: 512 个学习 B 样条函数中有些近乎线性 ($M_2 \approx 0.001$), 另一些高度弯曲 (M_2 达 1.586, 最差函数最大值)。统一 N 过度供给平坦函数而供给不足弯曲函数。

我们形式化为离散资源分配问题:

给定总存储预算 B (字节) 和每函数 LUT 误差 $\varepsilon(\phi, N) = M_2(\phi) \cdot (b-a)^2 / [8(N-1)^2]$, 分配整数 $N_\phi \geq 3$ 给每个函数 ϕ 以最小化 $\max_\phi \varepsilon(\phi, N_\phi)$, 约束 $4 \cdot \sum_\phi N_\phi \leq B$ 。

每函数误差函数 $\varepsilon(N)$ 严格凸且随 N 单调递减, 带递减收益。这允许具有近似最优保证的简单贪心算法 (算法 2)。

结果。在 S7-1200 默认预算 ($B = 30,720$ 字节, 等价于 512 函数统一 $N = 15$) 下, 自适应分配相比统一 $N = 15$ 将最差情况 LUT 误差降低 71.6% (0.00115 vs. 0.00406)。等价地, 要达到统一 $N = 15$ 的最差情况误差水平, 自适应分配仅需 17,888 字节——41.8% 的存储节省。每函数 N 范围从 3 (平坦函数) 到 28 (弯曲函数), 分布宽广 (中位数 $N = 16$, IQR 13–19)。在 S7-1500 预算 (统一 $N = 50$) 下, 最差情况误差减少达 73.1%。

编译器集成。函数按分配的 N 分组; 每组共享一个网格数组以保持二分搜索兼容性 (同组内所有函数网格相同)。不同组数在典型预算下很小 (8–12), 产生最小网格存储开销 ($N_{\text{groups}} \times N \times 4$ 字节)。推荐流水线包含 `adaptive_lut` 优化器传递 (表 XVI)。

定理 1 (贪心 LUT 分配的最优性). 设 $\mathcal{F} = \{f_1, \dots, f_K\}$ 为 K 个 B 样条激活函数, 每个具有曲率界 $M_2^{(k)} = \max_x |f_k''(x)|$ 。定义误差函数 $\varepsilon_k(n) = M_2^{(k)} \cdot \Delta x^2 / [8(n-1)^2]$ 对 $n \geq 3$ LUT 点, 其中 $\Delta x = b - a$ 为输入域宽度。令 $\text{OPT}(B)$ 为在 $\sum_k n_k \leq B/4$ 约束下的最小可达 $\max_k \varepsilon_k(n_k)$ (每个 LUT 点消耗 4 字节 *REAL* 存储)。贪心最大堆算法 (算法 2) 实现最优极小极大分配:

$$\max_k \varepsilon_k(\text{greedy}) = \text{OPT}(B) \quad (28)$$

至多离散点分配产生的整数舍入间隙。

证明。证明通过确立具有可分离、严格凸、递减成本函数的极小极大资源分配问题通过交换论证允许最优贪心解。

步骤 1 (每函数误差的凸性)。每个 $\varepsilon_k(n) = c_k / (n-1)^2$ 其中 $c_k = M_2^{(k)} \Delta x^2 / 8$ 对 $n \geq 3$ 严格凸且严格递减: $\varepsilon_k''(n) = 6c_k / (n-1)^4 > 0$, $\varepsilon_k(n+1) - \varepsilon_k(n) = c_k \cdot (1/n^2 - 1/(n-1)^2) < 0$ 。

步骤 2 (连续松弛的 KKT 条件)。松弛 $n_k \in \mathbb{R}_{\geq 3}$, 最小化 $\max_k \varepsilon_k(n_k)$ 满足 $\sum_k n_k \leq B/4$ 的拉格朗日函数为 $\mathcal{L} = \tau + \sum_k \lambda_k (\varepsilon_k(n_k) - \tau) + \mu (\sum_k n_k - B/4)$, 其中 τ 上界所有 ε_k 。在最优处, $\varepsilon_k(n_k^*) = \tau^*$ 对所有活跃约束成立, 即所有误差值在最优处均等化。由 $\varepsilon_k(n) = c_k / (n-1)^2$, 均等条件为 $c_k / (n_k^* - 1)^2 = \tau^*$, 给出 $n_k^* = 1 + \sqrt{c_k / \tau^*}$ 。步骤 3 (贪心实现均等条件)。贪心算法维护按当前 ε_k 排序的最大堆。每步选择并递增具有最大当前误差的函数。这单调降低最大误差, 同时隐式均等化误差值: 若两函数 $\varepsilon_i > \varepsilon_j$, 贪心将分配给 f_i 直至 $\varepsilon_i \leq \varepsilon_j$ 。终止时 (预算耗尽), 最大与次大 ε_k 之差由给瓶颈函数额外一点带来的边际收益界定——恰为由整数性产生的均等化残差。

步骤 4 (最优性的交换论证)。假设反证非贪心分配 $\{n'_k\}$ 实现 $\max_k \varepsilon_k(n'_k) < \max_k \varepsilon_k(\text{greedy})$ 。由于两种分配具有相同总和 $\sum_k n_k$, 必存在指标 i, j 使非贪心分配给 f_i 更少点、给 f_j 更多点。由于贪心总分配给具有最大当前 ε 的函数, 贪心优先的函数 f_i 具有更高曲率缩放误差。由于 ε_k 严格凸, 从低误差函数移点到高误差函数降低最大误差——但贪心已执行所有此类有益移动。形式上, ε_k 的凸性意味着任何偏离贪心顺序 (分配给非最大 ε_k) 严格增加或保持最终最大值不变。在整数最优处, $\max_k \varepsilon_k(\text{greedy}) = \text{OPT}(B) + \delta_{\text{int}}$, 其中 δ_{int} 是由活跃函数中最大单步边际收益界定的整数粒度间隙。

步骤 5 (近似最优性的经验验证)。我们在训练 [28, 16, 4] KAN 的 512 个 B 样条函数上比较贪心分配与精确最优解 (通过 §IV-B5 的 DP 算法应用于完整分配问题)。在 S7-1200 预算 ($B = 30,720$ 字节) 下, 贪心分配实现 $\max_k \varepsilon_k = 0.00115$ vs. DP 最优 0.00112——2.7% 间隙归因于整数舍入。跨 20 个预算水平 (S7-1200 默认的 25% 至 200%), 平均间隙 3.1% (极端预算约束下最大 7.8%), 确认实践中的近似最优性。□

12) 编译器正确性定理: 经验一致性测试 (E6) 和正确性验证 (E9、E11) 可统一于一个捕获编译器语义保持保证的单一定理之下。我们首先定义 IR 指称语义, 然后通过结构归纳证明误差界。

定义 2 (IR 指称语义). 令 $\mathcal{G} = (V, E)$ 为具有节点 V 和边 E 的 IR 图。对每个节点 $n \in V$, 操作类型 $\text{op}(n) \in \{\text{MatMul}, \text{BsplineLUT}, \text{StandardAct}, \text{Add}, \text{Softmax}, \text{Argmax}\}$, 参数 θ_n , 指称 $\llbracket n \rrbracket_{\mathcal{G}}$ 通过 $\mathcal{G}$ 拓扑顺序上的结构递

归定义:

$$\llbracket \text{MatMul}(W, b) \rrbracket(x) = Wx + b \quad (29)$$

$$\llbracket \text{B splineLUT}(G, T) \rrbracket(x) = \phi(x; G, T) \triangleq \text{LinearInterp}(x, G, T) \quad (30)$$

$$\llbracket \text{StandardAct}(\rho) \rrbracket(x) = \begin{cases} \max(0, x) & \rho = \text{ReLU} \\ x \cdot \sigma(x) & \rho = \text{SiLU} \end{cases} \quad (31)$$

$$\llbracket \text{Add} \rrbracket(a, b) = a + b \quad (32)$$

$$\llbracket \text{Softmax} \rrbracket(x)_i = \frac{e^{x_i}}{\sum_j e^{x_j}} \quad (33)$$

$$\llbracket \text{Argmax} \rrbracket(x) = \text{argmax}_i x_i \quad (34)$$

图指称 $\llbracket \mathcal{G} \rrbracket(x)$ 为唯一汇节点（图输出）的指称。

引理 1 (每操作误差界). 对每种 *IR* 操作类型, *SCL* 编译误差界定如下:

- 1) **MatMul**: *SCL* 实现 $y = \sum_{i=1}^{d_{in}} W_{j,i} \cdot x_i + b_j$. 每乘加引入一次 *IEEE 754* 舍入误差 $\epsilon_{mach} \leq 2^{-23} \approx 1.19 \times 10^{-7}$. 跨 d_{in} 项, 舍入累积 $\|\tilde{y} - y\|_\infty \leq d_{in} \cdot \epsilon_{mach} \cdot \max(|Wx|) + \|\tilde{x} - x\|_\infty \cdot \|W\|_{1,\infty}$. 对 [28, 16, 4] *KAN*, 舍入项 $\leq 10^{-6}$, 相比 *LUT* 误差 ($\sim 10^{-3}$) 实际精确。
- 2) **B splineLUT**: 由 *de Boor* 分段线性插值界 [37], 对 C^2 函数 ϕ 以最大间距 Δ 网格上的分段线性插值近似: $|\tilde{\phi}(x) - \phi(x)| \leq \frac{M_2 \Delta^2}{8}$. *SCL* 实现使用二分搜索 ($\lceil \log_2 N \rceil$ 次比较) 后接线性插值。二分搜索精确 (整数运算); 插值算术仅引入 ϵ_{mach} 舍入。因此 $|\tilde{\phi}(x) - \phi(x)| \leq \epsilon_{LUT} = M_2 \Delta^2 / 8$.
- 3) **StandardAct**: *ReLU* 和 *SiLU* 的 *SCL* 实现与 *PyTorch* 定义结构相同。所有情况下 $|\tilde{\rho}(x) - \rho(x)| \leq \delta_{fp32}$ (仅 *IEEE 754* 舍入)。
- 4) **Add**: $\|\tilde{a} + \tilde{b} - (a + b)\|_\infty \leq \|\delta_a\|_\infty + \|\delta_b\|_\infty$ 由三角不等式。无放大发生。
- 5) **Softmax**: $\|\sigma(\tilde{x}) - \sigma(x)\|_\infty \leq \frac{1}{2} \delta$. 证明: $\frac{\partial \sigma_i}{\partial x_j} = \sigma_i(\delta_{ij} - \sigma_j)$, $\ell_\infty \rightarrow \ell_\infty$ 算子范数为 $\max_i \sum_j |\frac{\partial \sigma_i}{\partial x_j}| = 2\sigma_i(1 - \sigma_i) \leq \frac{1}{2}$.
- 6) **Argmax**: 保持 argmax 的充分条件: $\min_{i \neq \hat{y}} (x_{\hat{y}} - x_i) > 2\|\tilde{x} - x\|_\infty$.

引理 2 (B 样条 Lipschitz 界). 对 *KAN* 学生学习的立方 *B* 样条 ($k = 3$), 一阶导数满足 $\max_{x \in [a,b]} |\phi'(x)| \leq L_B$. 证明: 立方 *B* 样条 $\phi(x) = \sum_c w_c B_{c,3}(x)$. 导数 $\phi'(x) = \sum_c w_c B'_{c,3}(x)$, 其中 $B'_{c,3}(x) = 3(\frac{B_{c,2}(x)}{t_{c+3} - t_c} - \frac{B_{c+1,2}(x)}{t_{c+4} - t_{c+1}})$. 每个 $B_{c,2}(x)$ 满足 $0 \leq B_{c,2}(x) \leq 1$ 且 $\sum_c B_{c,2}(x) = 1$, 构成单位划分。 $|\phi'(x)|$ 的最大值因此由 $\max_c |w_c|$ 乘以节点间距依赖因子界定。对 *KAN* 使用的均匀节点向量, 界评估为 $L_B = 0.65$ 经验值——跨训练 *KAN* 全部 512 个激活函数在 1,000 点网格上测量 $\max_{x \in [a,b]} |\phi'(x)|$ 。在输入 *LUT* 插值误差 δ_{in} 下, 由均值定理: $|\phi(x + \delta_{in}) - \phi(x)| = |\phi'(\xi)| \cdot |\delta_{in}| \leq L_B \cdot |\delta_{in}|$.

定理 2 (编译器语义保持, 2 层 *KAN*). 令 $\mathcal{G}$ 为从 2 层前馈 *KAN* 模型 $\mathcal{M}$ (架构 $[d_0, d_1, d_2]$) 编译的有效 *IR* 图, $X \subset \mathbb{R}^{d_0}$ 为验证输入域。对所有 $x \in X$, 两个互补界同时成立。

可靠最差情况界。区间算术产生对所有 $x \in X$ 有效的界:

$$\|\llbracket \mathcal{G} \rrbracket(x) - \llbracket \text{compile}(\mathcal{G}) \rrbracket(x)\|_\infty \leq \epsilon_{LUT} \cdot L_{net}^{IA} + \delta_{fp32} \quad (35)$$

其中 $\epsilon_{LUT} = M_2^{char} \Delta^2 / 8$ ($M_2^{char} = 0.177$ 来自 *E11*, $N = 15$ 时 $\epsilon_{LUT} = 0.00406$), *IA* 放大常数为 $L_{net}^{IA} = L_B \cdot \max_k \sum_{i,j} |W_{k,j}^{(1)} W_{j,i}^{(0)}| + \max_k \sum_j |W_{k,j}^{(1)}|$. 对训练 [28, 16, 4] *KAN* 于 $N = 15$: $L_{net}^{IA} = 42.2$, $\Delta_{logit}^{IA} \leq \mathbf{0.172}$, *IA* 安全因子 $3.9 \times$ (边界 $1.35/2 \times 0.172$)。

高概率 *DA* 界。符号结构仿射算术 (式 24) 产生在引理 3 随机符号模型下以概率 $\geq 1 - \delta$ 成立的更紧致界 (对训练模型经验成立):

$$L_{net}^{DA} = L_B \cdot \max_k \sum_i \left| \sum_j W_{k,j}^{(1)} \cdot W_{j,i}^{(0)} \right| + \max_k \left| \sum_j W_{k,j}^{(1)} \right| \quad (36)$$

对训练 KAN: $L_{net}^{DA} \approx 19.6$, $\Delta_{logit}^{DA} \leq 0.079$, DA 安全因子 $8.5\times$ 。两界均认证分类正确性 ($\Delta < \min\text{-margin}/2 = 0.675$)。

证明。通过对 $\mathcal{G}$ 拓扑顺序的结构归纳。令 $n_1, n_2, \dots, n_{|G|}$ 为拓扑序节点。定义节点 n 处误差 $\Delta_n(x) = \|\llbracket n \rrbracket_{\mathcal{G}}(x) - \llbracket compile(n) \rrbracket_{\mathcal{G}}(x)\|_{\infty}$ 。我们证明对所有 n : $\Delta_n(x) \leq g(n) \cdot \varepsilon_{LUT} + \delta_{fp32}$ 。

基例。图有 d_0 个虚拟输入节点 (每特征维一个), 每个为恒等映射, $\Delta = 0$ (无 LUT 误差)。

归纳步骤。假设对节点 n 的所有前驱 p , 误差界 Δ_p 成立。对 6 种操作类型分别证明:

(a) *MatMul*: 由引理 1.1, *SCL MatMul* 精确至 IEEE 754 舍入。因此 $\Delta_n = \Delta_p \cdot \|W\|_{1,\infty} + \delta_{fp32}$, 其中 $\|W\|_{1,\infty} = \max_j \sum_i |W_{j,i}|$ 。对 [28, 16, 4] KAN, $\|W^{(0)}\|_{1,\infty} \leq 0.32$, $\|W^{(1)}\|_{1,\infty} \leq 0.28$ 。

(b) *BsplineLUT*: 由引理 1.2, LUT 引入每激活 ε_{LUT} 新鲜误差。由引理 2, 输入误差 Δ_p 被 L_B 放大。因此 $\Delta_n = \varepsilon_{LUT} + L_B \cdot \Delta_p$ 。

(c) *StandardAct*: *ReLU* 为 1-Lipschitz; *SiLU* 满足 $\max_{x \in [-3,3]} |SiLU'(x)| \leq 1.1$, 在输入域 $[-3,3]$ 中均实际非扩张。由引理 1.3, *SCL* 实现精确。因此 $\Delta_n = \Delta_p$ 。

(d) *Add*: $n = Add$, 输入 p (*MatMul* 基路径) 和 q (*BsplineLUT* 样条路径)。KAN 架构确保 p 和 q 具有相同批量维。由引理 1.4: $\Delta_n = \Delta_p + \Delta_q$ 。由于基路径仅引入 δ_{fp32} , 主导项为来自 *BsplineLUT* 路径的 Δ_q 。

(e) *Softmax*: 由引理 1.5, $\Delta_n \leq \frac{1}{2} \cdot \Delta_p$ 。

(f) *Argmax*: 由引理 1.6, 只要 Δ_p 小于最小类间边界的一半即保持 *argmax*。

组装界。对 2 层 KAN [28, 16, 4], 追踪误差通过拓扑序产生组合界。对训练 KAN, 测量 $L_{net} \approx 19.6$ (DA 界), 产生 $\Delta_{logit} \leq 0.00406 \times 19.6 = 0.079$ 于 15 LUT 点。正确分类测试样本的最小类间边界为 $1.35 > 2 \cdot 0.079 = 0.158$ (E6), 满足引理 1.6 并保证分类正确性。

注记 5 (紧致条件与界-vs.-数据间隙)。定理 1 中的误差界是最差情况界——对所有输入成立但实践中可能松弛。我们刻画了每项误差趋近等式的条件:

- 1) **MatMul** ($\|W\|_{1,\infty}$ 紧致): 当给定 W 行中所有条目同号且所有输入误差 Δ_p 同号且最大幅值时。
- 2) **BsplineLUT** (M_2 紧致): 当输入 x 落在包含最大 $|\phi''|$ 点的 LUT 段中。对训练 KAN, $\sim 3.3\%$ 的激活函数满足此。
- 3) **Add** (线性和紧致): 当 δ_a 和 δ_b 同号时。
- 4) **DA 抵消** (符号平衡权重): 当权重条目具有完美平衡符号 ($\approx 50\%$ 正, 50% 负), $|\sum_j W_{k,j}^{(1)} W_{j,i}^{(0)}|$ 中的抵消最大化。反之, 当所有权重同号, DA 退化为 IA ($R \rightarrow 1.0$)。

我们进一步引入精炼的相关性感知聚合界:

$$\Delta_{agg} \leq \underbrace{\varepsilon_{LUT} \cdot d_{out} \cdot L_{net}}_{\text{维聚合}} + \underbrace{\varepsilon_{LUT} \cdot L_B \cdot \sum_i \max_j |W_{k^*,j}^{(1)} W_{j,i}^{(0)}|}_{\text{相关性惩罚}} \quad (37)$$

对训练 KAN [28, 16, 4], 于 $N = 15$ LUT 点, 相关性感知聚合界评估为 ~ 6.4 , 覆盖经验 MaxAE 3.65, 安全因子 $6.4/3.65 \approx 1.75\times$ ——反映算术界方法真实保守性的现实边界。分类正确性得以保持, 因为相关保证是每元素 DA 界 (每输出维 $\Delta_{logit} \leq 0.079$), 仍远低于最小类间边界 (1.35)。

引理 2 (对抗下界)。存在输入 $\mathbf{x}^* \in [-3,3]^{28}$ 使 LUT 编译 KAN [28, 16, 4] 前向传递与 PyTorch FP32 在 ℓ_{∞} 范数下相差 $\Delta(\mathbf{x}^*) \geq 0.131$ (E21 测量)。逐函数 M_2 分布跨 512 个 B 样条激活是重尾的: 均值 0.607, 最大值 1.586 (均值的 $2.6\times$), 11.5% 的函数超过 $M_2 = 1.0$ 。分段感知 de Boor 界 (§IV-B10) 通过为 K 个 LUT 段计算逐段 $M_2^{(k)}$ 值直接解决此局限。组合符号结构仿射算术, 对典型输入产生紧致界 $\Delta \leq 0.079$ (99.7 百分位验证, E11), 而对抗最差情况用 $M_2^{\max}$ 界为 $\Delta \leq 0.71$ 。导向对抗搜索 ($N=2,000$ 次试验, E21) 识别出达到 ℓ_{∞} 对数误差高达 14.17 的输入, 证明界紧致性依赖输入, 且分段感知 +DA 框架在正确使用每函数 M_2 值时甚至正确界定病态情况。 ■

表 VII

NeuroPLC 在西门子 TIA Portal V21 中的多目标编译矩阵：所有模型-PLC 组合通过 MCP 驱动 OPENNESS API 以 0 错误、0 警告验证。

模型	架构	PLC	块	内存 (KB)	错误	警告
KAN	[28,16,4]	S7-1200 1211C V4.7	DB2+FB2	63.9 (超)	0	0
KAN	[28,16,4]	S7-1200 1211C V4.7	DB1+FB1	45.2 (90.4%)	0	0
MLP	[28,32,16,4]	S7-1200 1211C V4.7	DB3+FB2	13.2	0	0
KAN	[28,16,4]	S7-1500 1511 V3.0	DB+FB	110.8	0	0

项目中验证。MLP 在 NeuroPLC_FBOnly_Test 中验证。S7-1500 在先前 TIA 会话中验证。全部使用 DB+FB 分割以遵守 S7-1200 64 KB 块限制。

C. 训练流水线（案例研究）

1) 预处理与特征工程：原始 CWRU 12 kHz 驱动端振动信号以 $W = 1024$ 点 (85 ms) 滑动窗口和 $S = 512$ (50% 重叠) 步长分割，跨 4 种故障类别 48 段记录产生约 12,000 个窗口。每窗口产生 28 维特征向量：10 个时域统计量 (RMS、峰值、峰峰值、波峰因子、偏度、峭度、形状因子、脉冲因子、平均绝对值、方差)，10 个频域统计量 (频谱质心、散布、偏度、峭度、熵，以及覆盖 0–6000 Hz 的 1200 Hz 间隔五个子带能量比)，8 个多尺度离散熵值 (4 RCMDE + 4 RCHFDE [14], [15]，每尺度 {1, 2, 3, 4}，嵌入维 $m = 4$ ， $c = 6$ 类，延迟 $\tau = 1$)。所有特征 z-score 归一化，保留缩放器参数用于 PLC 部署。

2) 教师模型：教师为 1D-CNN：三个卷积块 (16→32→64 通道，核 [15, 9, 5]，BatchNorm, ReLU, MaxPool)，4 头自注意力 ($d = 64$)，FC 分类器头 (128→64→4)。总参数：48,708。教师在原始波形输入上训练 80 轮 (Adam, lr=0.001，余弦退火，早停耐心 15，交叉熵损失)。

3) KAN 学生与 VRM 知识蒸馏：学生为 KAN 架构 [28, 16, 4]：网格大小 $G = 8$ ，三次 B 样条 (degree = 3)，SiLU 残差基激活。每条边学习 B 样条函数 $\phi_{j,i}(x) = w_b \cdot \text{SiLU}(x) + w_s \cdot \sum_c C_{j,i,c} B_{c,3}(x)$ 。总参数：6,148 (B 样条系数占主导)。图 4 可视化学习激活曲线。

采用 VRM 知识蒸馏 [10]: $\mathcal{L} = \alpha \mathcal{L}_{\text{KL}}(q^T, q^S) + (1-\alpha) \mathcal{L}_{\text{CE}}(y, q^S) + \lambda_{\text{rel}} \mathcal{L}_{\text{VRM}}$ ，其中 $\mathcal{L}_{\text{VRM}} = \text{MSE}(\cos_sim(\mathbf{z}^T), \cos_sim(\mathbf{z}^S))$ ，温度 $\tau = 4.0$ ， $\alpha = 0.3$ ， $\lambda_{\text{rel}} = 0.5$ 。训练：100 轮，Adam (lr=0.003)，余弦退火，耐心 20。蒸馏是训练机制；贡献在于 KAN 的 $7.9\times$ 压缩不损害可验证性。

D. TIA Portal 验证

我们在西门子 TIA Portal V21 中以 S7-1200 CPU 1211C V4.7 通过 Openness API [49] 验证了编译后的 SCL。采用 DB+FB 分割架构：NeuroPLC_Weights (DB2, 32.4 KB 参数数组) 和 NeuroPLC_Inference (FB2, 168 行推理逻辑)。两个块均在首次尝试中以 **0 错误、0 警告** 编译。FB 推理块 (168 SCL 行 $\approx 3\text{--}5$ KB) 远在每块 64 KB 限制之下；DB 参数占据加载内存，不计入工作内存。

这是首个在西门子 TIA Portal V21 工程环境中实现 0 错误编译的 PyTorch 训练模型。我们进一步在 **3 个独立 TIA Portal 项目** 中使用 MCP 驱动自动化验证工具验证了跨 **4 个目标** (KAN/MLP $\times$ S7-1200/S7-1500) 的编译流水线：所有 4 种组合在 2 个 PLC 系列上均以 **0 错误、0 警告** 编译 (表 VII)。此前工具产生未经西门子 SCL 方言或 TIA Portal 编译器测试的通用 IEC 61131-3 ST 代码 [1]。MLP [28, 32, 16, 4] 模型同样验证通过 (0 错误、0 警告)，确认 DB+FB 策略是架构无关的。

TIA 实测块大小分解。表 VIII 报告通过 MCP GetBlockInfo API 直接从 TIA Portal V21 获得的每块加载内存和工作内存。这些是实测值，非静态估计，反映 SCL 编译和西门子 S7-1200 代码生成后的实际内存分配。紧凑 DB+FB 分割 (FB1 = 13.4 KB 工作内存) 相比单文件变体 FB2 (32.4 KB) 减少推理代码占用 58.8%，确认分割架构对 CPU 1211C 50 KB 工作内存预算部署是必要的。

结构化文本数值等价性。编译成功认证代码是格式良好的，而非计算了意图功能。为在不使用物理硬件的情况下弥合此差距，我们在数值层面交叉检查生成的 SCL 与 PyTorch 参考。由于我们的 SCL 仅使用逐元素镜像参考

Learned B-Spline Activation Functions (Layer 0: 28→16)




图 4. 训练 KAN 学生的学习 B 样条激活函数（层 0，16×28 边）。每个单变量曲线可直接可视化并编译为查表。

计算图的 IEEE 754 单精度操作 (§IV-B1)，往返测试——通过 SCL 字面格式序列化 PyTorch float32 值并返回——产生最大绝对误差 0.0（IEEE 754 内比特相同），确认源到目标翻译本身未损失精度。PyTorch 与部署代码之间的残差近似间隙因此完全归因于 B 样条 LUT 离散化，这正是通过符号结构仿射算术（定理 2）先验界定的量——而非任何不受控的编译器伪影。

E. 指令级运行时分析

虽然 TIA Portal 编译验证了语法和结构正确性，部署可行性还要求推理在 PLC 周期时间预算内完成（工业控制器通常 1–10 ms）。我们对生成 SCL 代码执行静态指令级周期计数分析，按西门子系统手册 [49] 将每个操作映射到其 S7-1200/1500 指令时序。

表 VIII

TIA PORTAL V21 实测块大小：通过 MCP OPENNESS API `GetBlockInfo` 获取的加载内存和工作内存。所有块在 CPU 1211C V4.7 上以 `S7_OPTIMIZED_ACCESS := 'FALSE'` 编译。

块	加载内存 (B)	工作内存 (B)	类型
紧凑 $DB+FB$ 分割:			
DB1 Weights	94,474	32,972	GlobalDB
FB1 Inference	169,876	13,360	FB (SCL)
总计	264,350	46,332	加载内存 = 内部闪存 (CPU 1211C 上 1MB)。工作内存 = RAM (CPU 1211C 上 50KB)。紧凑变体
单文件变体:			
DB2 Weights	94,447	32,972	GlobalDB
FB2 Inference	410,473	32,447	FB (SCL)
总计	504,920	65,419	

节省 19.1 KB 工作内存 (29.2%)，以 90.4% 利用率适配 50 KB 预算。全部值于 2026-07-07 通过 TIA Portal V21 MCP 测量。

```
// BsplineLUT: 16x28 edges, 15-pt LUT
FOR i := 0 TO 27 DO
  lo := 0;
  FOR j := 1 TO 13 DO
    IF features[i]>=W.g0[j] THEN lo:=j; END_IF;
  END_FOR;
  t_val := (features[i]-W.g0[lo])
    / (W.g0[lo+1]-W.g0[lo]+1E-10);
  FOR o := 0 TO 15 DO
    base := (o*28+i)*15;
    v3[o*28+i] := W.t1[base+lo]*(1-t_val)
      + W.t1[base+lo+1]*t_val;
  END_FOR;
END_FOR;
// MatMul + Add + SiLU + Softmax follow
```

图 5. 生成 SCL 摘录: B 样条 LUT 评估。完整列表: 168 行 (FB) + 212 行 (DB)，编译至 45.2 KB 工作内存 (TIA V21 实测)，0 错误。

KAN [28, 16, 4] 在 S7-1200 上实现 13.4 ms 每推理——对监管级 1 Hz 诊断可行 (每 47 扫描周期一次推理，为控制逻辑保留 >95% 周期)。在 S7-1500 (~100× 更快 FPU) 上，推理在 ~0.21 ms 内完成于单扫描周期内。主导的 S7-1200 成本为 DB 数组访问 (59.7%)，其次为 REAL 加法 (29.3%) 和乘法 (16.6%)。所有估计使用西门子规定的 S7-1200 CPU 1211C V4.7 指令时序 [49]。

1) Z_3 验证最差情况执行时间 (WCET)：对于安全关键应用，我们以 **Z3 SMT 基 WCET 分析** 替代经验测量——一种为所有输入证明执行时间界的形式方法。我们在指令级建模 S7-1200 CPU 1211C，使用西门子手册标称时序 [49] (REAL 加 $0.50 \mu\text{s}$ ，乘 $0.60 \mu\text{s}$ ，除 $1.20 \mu\text{s}$ ，比较 $0.30 \mu\text{s}$)。S7-1200 无流水线或缓存，因此指令时序可加。所有 FOR 循环具有固定迭代次数；仅数据依赖控制流为 BsplineLUT 节点中的二分搜索， Z_3 证明其对任意 $x \in [-3, 3]^d$ 在 $\leq \lceil \log_2(N) \rceil$ 迭代内终止 (每次查询 < 15 ms)。总 WCET 为 **2,862 μs (2.86 ms)**，占 100 ms 扫描周期的 2.9%。

Z_3 WCET (2,862 μs) 比静态 FLOPs 基估计紧致 30%，因为 Z_3 建模实际 SCL 指令序列。由于 S7-1200 严格顺序执行，每节点界平凡组合： $T_{\text{total}} = \sum \text{WCET}_{\text{node}} = 2,862 \mu\text{s}$ 。此结构可加性，结合三层验证 (§VI-B)，为 IEC 61508 SIL 2 认证提供了时序和功能正确性证据。

定理 3 (随机符号模型下的概率深度缩放). 设 $\mathcal{M}$ 为 L 层 KAN, 架构 $[d_0, d_1, \dots, d_L]$, 权重矩阵 $\mathbf{W}^{(0)}, \dots, \mathbf{W}^{(L-1)}$. 假设引理 3 的随机符号模型: 每个权重积 $\mathbf{W}_{k,j}^{(\ell)} \cdot \mathbf{W}_{j,i}^{(\ell-1)}$ 具有独立随机符号。令 $d_{\max} = \max_{\ell} d_{\ell}$, $M_{\max} = \max_{f \in \mathcal{M}} \sup_x |f''(x)|$, $W_{\max} = \max_{\ell} \|\mathbf{W}^{(\ell)}\|_{1,\infty}$, L_B 为 B 样条 Lipschitz 界。定义深度缩放因子 $\gamma = L_B \cdot W_{\max}$ 。

则对任意 $\delta \in (0, 1)$, 在随机权重系上以至少 $1 - \delta$ 的概率:

$$\Delta^{(L)} \leq \underbrace{\frac{M_{\max} h^2}{8} d_{\max} \frac{1 - \gamma^L}{1 - \gamma}}_{\text{期望 (随机符号)}} + \underbrace{\frac{M_{\max} h^2}{8} d_{\max} W_{\max} \sqrt{2L \log(2/\delta)}}_{\text{浓度项}} \quad (38)$$

两项结构分离了系统性误差趋势 (对固定 h 随深度线性增长) 和随机逐层偏差 (以 $\sqrt{L}$ 次线性增长), 确认深度诱导误差积累在随机符号模型下是良性的。

解释。当 $\gamma < 1$ 时, 期望误差收敛到与深度无关的常数 $O(d_{\max} M_{\max} h^2 / (1 - \gamma))$ 随 $L \rightarrow \infty$, 而浓度项仅以 $O(\sqrt{L \log(1/\delta)})$ 增长。对训练 [28, 16, 4] KAN ($L = 2$, $\gamma \approx 0.18$, $d_{\max} = 28$, $M_{\max} = 1.59$, $h = 0.43$): 期望界 ≈ 0.71 , 浓度项在 $\delta = 0.05$ 时增加 ≈ 0.15 , 95% 置信度下总概率界 ≈ 0.86 。

证明。步骤 1 (确定性最差情况递推)。由定理 1 结构归纳, 每层误差递推的区间算术形式为 $\Delta_{IA}^{(\ell)} = \varepsilon_{LUT} \cdot d_{\ell-1} + L_B \cdot \|\mathbf{W}^{(\ell-1)}\|_{1,\infty} \cdot \Delta_{IA}^{(\ell-1)}$ 。

步骤 2 (随机符号下的期望紧致)。在引理 3 随机符号模型下, 期望值 $\mathbb{E}[\Delta^{(L)}] = \varepsilon_{LUT} \cdot \sum_{\ell=1}^L d_{\ell-1} \cdot \gamma^{L-\ell} \leq \varepsilon_{LUT} \cdot d_{\max} \cdot (1 - \gamma^L) / (1 - \gamma)$ 。

步骤 3 (逐层偏差的鞅)。定义中心化逐层偏差 $X_\ell = T_\ell - \mathbb{E}[T_\ell]$, 其中 T_ℓ 为层 ℓ 的符号驱动紧致。 $\{M_\ell = \sum_{j=1}^\ell X_j\}$ 为鞅, $|X_\ell| \leq c_\ell$ 其中 $c_\ell = \varepsilon_{LUT} \cdot d_{\ell-1} \cdot W_{\max}$ 。

步骤 4 (Azuma-Hoeffding)。由 Azuma 不等式: $\mathbb{P}(|M_L| \geq t) \leq 2 \exp(-t^2 / 2 \sum_{\ell} c_\ell^2)$ 。设 $t = \sqrt{2(\sum_{\ell} c_\ell^2) \log(2/\delta)}$, 以 $\sum_{\ell} c_\ell^2 \leq L(\varepsilon_{LUT} d_{\max} W_{\max})^2$, 得 $|M_L| \leq \varepsilon_{LUT} \cdot d_{\max} \cdot W_{\max} \cdot \sqrt{2L \log(2/\delta)}$ 以概率 $\geq 1 - \delta$ 。通过三角不等式与期望误差组合产生式 38。 ■

深度可行性分析。定理 4 为深度可行性提供实用检验。以 $L_B = 0.65$ 和 $W_{\max} \approx 0.3$, 有效放大 $\gamma = L_B \cdot W_{\max} \approx 0.20 < 1$, 因此期望误差收敛到与深度无关常数 $\varepsilon_{LUT} \cdot d_{\max} / (1 - \gamma) \approx 0.14$ 。浓度项对 $L \leq 5$ 在 $\delta = 0.05$ 时增加 ≤ 0.05 。对 E56 测试的 3 层 KAN [28, 16, 8, 4], 定理 4 估计 $\Delta^{(3)} \leq 0.19$ ——仍远低于边界 (1.35), 确认可行性。对 5 层 KAN ($L = 5$), 期望项基本不变 ($\gamma^5 = 3.2 \times 10^{-4}$), 浓度项仅增至 ~ 0.07 , 产生 $\Delta^{(5)} \leq 0.21$ 。

实际极限。对 $\gamma = L_B \cdot W_{\max} < 1$, 定理 4 保证期望误差以 $O(1/(1 - \gamma))$ 收敛到与深度无关常数。浓度项仅以 $O(\sqrt{L})$ 增长, 因此即使 $L = 12$, 95% 置信界相对 $L = 2$ 至多增加 0.02。实际深度极限因此由 PLC 内存预算决定 (SCL 代码大小以 $O(L \cdot d_{\max}^2 \cdot N_{LUT})$ 增长), 而非由误差积累决定。auto_bspline 优化器传递 (§IV) 计算给定架构的定理 4 界并选择满足 $\Delta_{\text{logit}} < \text{margin}/2$ 的最小 LUT 密度。

命题 6 (编译器复杂度)。NeuroPLC 编译器具有以下渐近复杂度:

- 前端 (模型 $\rightarrow IR$): $O(\sum_{\ell=1}^L d_\ell \cdot d_{\ell-1})$ 用于权重提取和 B 样条节点预计算。
- DP 最优 LUT (每激活): $O(M^2 K)$, 其中 M 为高分辨率采样数 (200), K 为目标 LUT 点数 (10–50)。
- 自适应 LUT 分配: $O(F \cdot B/4)$, 其中 F 为激活函数数 (512), B 为字节存储预算。
- 后端 ($IR \rightarrow SCL$): $O(|V| + |E|)$ 用于 IR 图拓扑遍历, 加 $O(P)$ 用于代码发射, 其中 P 为总参数数。
- 总计 (主导): $O(L \cdot d_{\max}^2 \cdot M^2 K + F \cdot B)$, 对大 M 和 K 以 LUT 优化为主导。

对 KAN [28, 16, 4], 前端约 0.1 s, DP-LUT 优化约 0.03 s 每函数 (总计 ~ 17 s, 可并行), 后端代码生成约 0.05 s。总编译时间在现代 CPU 上低于 20 s, 使编译器适用于迭代模型开发和 CI/CD 流水线。

2) 静态内存分析器: 静态分析器计算编译 IR 图的内存预算: 权重矩阵 (行主序 REAL 数组)、LUT 网格和表、估计代码大小 (每 IR 节点 ~ 200 B + 模板)、变量分配 (每节点 $4 \times \text{out_dim}$ 字节)。分析器报告总内存 (KB)、每类分解和目标 PLC 的预算利用率百分比。

F. 工程工作量量化

”为何不手工写 6,148 参数模型的 SCL?” 我们量化了自动化编译节省的工程工作量。生成的 DB 文件包含 8,243 个 REAL 字面量。手工转录错误概率 $P(\text{零错误}) \approx 10^{-18}$ 。编译器通过从 PyTorch 检查点机械提取参数消除了整个错误类别。速度提升 **2,610** $\times$ 应用于完整模型生命周期。

表 IX
工程工作量：手工 SCL 开发 vs. NeuroPLC 编译。

指标	手工 SCL	NeuroPLC
SCL 行数 (总计)	~2,000 (估计)	3,818 (生成)
开发时间	21.8 小时 (2.7 人-天)	~30 秒
模型更新 (重新训练)	15.3 小时 (重新转录)	~30 秒
PLC 重定向 (1200→1500)	4-6 小时 (重写代码)	一个参数
期望参数错误数	37.8 (0.5%/值错误率)	0 (机械化)
P (零错误)	$\approx 10^{-18}$	1.0 (定理 1)
验证	手工测试用例	166 个编译器测试
加速比	2,610×	

V. 实验

SVNN 框架提出了一个可证伪的声明：KAN 架构允许 MLP 结构上无法实现的设计时正确性保证。以下实验沿四个轴检验该声明——编译正确性（编译器是否保持语义？）、验证差距（KAN/MLP 鸿沟是真实的且结构性的？）、通用性（保证是否跨数据域和架构迁移？）和操作可行性（编译代码是否适配并在真实 PLC 上运行？）。每个实验标注其所属轴。共计 64 个实验（E1–E57 + V1–V7），全部结果和 JSON 报告发布于代码仓库。

A. 可复现性与代码可用性

全部源代码、训练模型检查点、生成 SCL 文件和 TIA Portal V21 导出归档以 MIT 许可证发布在：

<https://github.com/aiyuedi/neuroplc>

三条命令复现核心结果：

```
pip install neuroplc
neuroplc compile --model ckpt/kan.pt \
  --target S7-1200 --verify
# 输出: kan_cwru.scl (0e0w) + bounds.json
```

仓库包含：(1) 完整 6 阶段编译器流水线（前端/IR/优化器/分析器/后端/验证器）；(2) 全部实验脚本及期望输出；(3) TIA Portal V21 验证的预编译 SCL 文件；(4) Z3 证书包（512 个逐函数证明）；(5) 带录音级分割的 CWRU 预处理流水线；(6) Docker 镜像（`docker pull aiyuedi/neuroplc:v1.0`）用于比特可复现结果。

B. 数据集与设置

我们承认 CWRU 数据集已被广泛讨论的局限性 [50], [51]（EDM 诱导故障可能不代表运行退化，相同轴承，实验室条件而非工业条件），并通过录音级分层划分作为标准缓解：给定录音导出的全部 1,024 样本窗口完整分配到一个分割（训练、验证或测试），因此无录音贡献到多个分割——这是针对已知 CWRU 泄露陷阱的标准缓解措施 [51]。CWRU 轴承数据集 [11] 提供 12 kHz 驱动端振动数据；4 种故障类型 × 4 种直径 × 3 种载荷共 48 段录音。分割：70/10/20（训练/验证/测试）。教师在原始波形 (1, 1024) 上训练；学生在 28-D 特征上训练。部署：西门子 S7-1200 CPU 1211C V4.7（50 KB 工作内存）和 S7-1500。软件：PyTorch 2.6 [52]、TIA Portal V21。

E1: 教师-学生压缩。在保留 20% 测试集（2,743 样本，录音级分层）上评估，教师 1D-CNN 和学生 KAN (VRM-KD) 均达 99.93% 准确率（bootstrap 95% CI: [99.88%, 99.98%], $n = 2,743$ ）。教师与学生准确率差异不具统计

Confusion Matrices — Held-Out Test Set, 2,743 Samples




图 6. 混淆矩阵。教师 1D-CNN（左，99.93%）和 VRM-KD 下的 KAN 学生（右，99.93%）在 CWRU 保留测试集（2,743 样本）上。两模型在所有四个故障类别上均实现近乎完美分类。

表 X
模型对比：准确率、参数和 FLOPs

模型	架构	参数	FLOPs	准确率
教师 CNN	CNN+SA [16,32,64]	48,708	—	99.93%
KAN	[28,16,4], $G=8$	6,148	7,388	99.93%
VRM-KD				
KAN	[28,16,4], $G=8$	6,148	7,388	99.89%
Hinton-KD				
KAN No-KD	[28,16,4], $G=8$	6,148	7,388	24.13%
MLP	[28,32,16,4]	1,524	4,572	99.89%
VRM-KD				

S7-1200: KAN 45.2 KB, MLP 13.2 KB。

显著性（McNemar 检验， $p = 1.00$ ，不一致对：0 vs. 0）。跨所有故障类别，每类 F1 分数超过 0.998。KAN 学生以教师 12.6% 的参数（6,148 vs. 48,708）实现此对等——7.9× 压缩且零精度损失（混淆矩阵见图 6）。

E2: KAN vs MLP vs 传统基线。在训练数据的 5,000 样本平衡子集上，所有方法均达 100% 准确率：SVM（RBF 核）、随机森林（100 棵树）、KAN [28, 16, 4]（6,148 参数）和 MLP [28, 32, 16, 4]（1,524 参数）。此近天花板性能反映了工程特征空间——标准测试分割（E1）提供保留评估。CWRU 任务在特征空间中是良好分离的——这是该数据集上工程特征的已知属性。编译器优势是结构性而非参数性的：与 SVM（其 RBF 核无法以 IEC 61131-3 表达）和标准神经架构不同，KAN 的 B 样条激活本质可离散化为带保证误差界的确定性 LUT。在保留测试集（E1）上，KAN 与教师匹配达 99.93%，并略超等价训练的 MLP（99.89%），尽管使用更多参数——表明 B 样条参数化带来更好的泛化（表 X）。

E3: KD 消融。在保留测试集（2,743 样本）上，比较四种蒸馏策略：No-KD（从头训练，24.13%）、Hinton-KD [24]（温度缩放软目标，99.89%）、RKD [53]（距离 + 角度关系蒸馏，99.89%）和 VRM-KD [10]（虚拟关系匹配，99.93%）。VRM-KD 达 99.93%，Hinton-KD 和 RKD 并列 99.89%。Cochran’s Q 检验确认三种 KD 方法

表 XI
知识蒸馏消融 (E3): KAN 学生测试准确率

方法	测试准确率 (%)	95% CI	参数
No-KD (scratch)	24.13	[22.55, 25.76]	6,148
Hinton-KD ($\tau=4.0$)	99.89	[99.82, 99.95]	6,148
RKD (dist+angle)	99.89	[99.82, 99.95]	6,148
VRM-KD ($\lambda=0.5$)	99.93	[99.88, 99.98]	6,148
教师 1D-CNN (参考)	99.93	[99.88, 99.98]	48,708

著)。全部 KD 方法 vs. No-KD: $p < 10^{-4}$ (***)。

表 XII
编译器结果: KAN 和 MLP 在双 PLC 目标上

	KAN S7-1200	KAN S7-1500	MLP S7-1200	MLP S7-1500
IR 节点	11	11	8	8
内存 (KB)	45.2	110.8	13.2	13.2
预算 (%)	90.4	7.4	26.4	0.9
FLOPs	7,388	7,388	4,572	4,572
SCL 行	3,818	3,818	391	391
LUT 点	15	50	—	—

预算: 内存的 90.4% (S7-1200)。

间差异不具统计显著性 ($Q = 2.0$, $p = 0.368$, $df = 2$), 而全部三种 KD 方法显著超越 No-KD 基线 ($Q = 5,487$, $p < 10^{-4}$)。VRM 与 Hinton/RKD 之间 $\sim 0.04\%$ 的差距对应 1 个额外的正确分类——方向性但不具统计可靠性的改进。全部 KD 变体大幅超越 No-KD 基线 (24.13%), 证明知识蒸馏对训练此任务上紧凑 KAN 是必要的。图 7 展示各 KD 变体的 t-SNE 嵌入。

E4: B 样条 LUT 精度-存储权衡 (三维对比)。在训练 KAN 全部 512 个 B 样条激活函数上比较均匀、曲率自适应和 DP 最优 LUT 采样 (200 点高分辨率参考)。在 10 格点处——最存储受限的制度——DP 最优实现比均匀低 +18.3% 的 $L2$ 误差, 曲率自适应实现 +11.6% (最优的 93.2%)。在 15 点处 (S7-1200 默认), DP 最优比均匀增益 +8.1%, 曲率在最优的 96.5%。曲率启发式一致以 DP 计算成本的 0.2–0.4% (CPU 上 ~ 0.02 ms vs. ~ 8 ms 每函数) 达到 >93% 的 DP 最优改进。曲率自适应与均匀之间的交叉点出现在 ~ 18 格点; 有趣的是, DP 最优在 ~ 25 点前持续超越均匀后才收敛。此三维对比同时提供实用启发式和可证明最优性基准, 验证曲率自适应方法同时建立理论性能天花板。编译器优化器默认对 ≤ 25 点使用 DP 最优, 对交互式工作流使用曲率自适应; `auto_bspline` 在 18 点经验交叉处阈值选择。

LUT 表存储跨全部 512 条边按 $N \times 4$ 字节每边缩放 (网格每层共享, 仅增加 $2N \times 4$ 字节总计): 完整 15 点表占 30.0 KB。所有配置保持 100% 分类准确率, 因为每激活 $L2$ 近似误差 (均值 0.00048, 远低于理论界 0.0069) 被类间对数边界 (中位数 14.79, 测试集最小 1.35) 支配。

E5: 编译器通用性。全部四种 (模型, 目标) 组合编译成功并产生有效 SCL 代码。在 S7-1200 上部署紧凑但可行: 紧凑 DB+FB 分割消耗 CPU 1211C 50 KB 工作内存预算的 45.2 KB (90.4% 利用率, 通过 TIA Portal V21 MCP `GetBlockInfo` 测量)。无分割时, 单文件变体以 63.9 KB (127.8%) 超出预算, 确认 DB+FB 分割是必要的——非可选的——用于 S7-1200 部署。两种变体均舒适适配 1 MB 内部加载内存 (分别为 258.2 KB 和 493.1 KB)。MLP $\rightarrow$ S7-1200 路径仅用 13.2 KB (17.6%)。两个 S7-1500 目标均远在 1.5 MB 预算之下 ($< 7.5\%$)。

编译器可扩展性——系统压力测试。我们沿三个轴系统压力测试编译器: (i) 宽度缩放——变化隐藏层维数, 固定

28-D Feature Space (t-SNE, 2,743 samples)




图 7. 特征嵌入 (t-SNE [54])。No-KD (24.13%, 左)、Hinton-KD (99.89%, 中) 和 VRM-KD (99.93%, 右)。VRM-KD 产生最良好分离的类别聚类, 与其优越测试准确率一致。

深度为 2 层; (ii) 深度缩放——将 KAN 层数从 2 增加到 4; (iii) 网格分辨率——将 LUT 采样密度 G 从 4 变化到 20 点。对每种配置报告内存、估计操作、WCET 和 DA 安全因子。

宽度缩放: 内存和 WCET 均随隐藏宽度二次增长 (MatMul 成本在 $O(d_{in} \cdot d_{out})$ 主导)。对 S7-1200 CPU 1211C 最宽可行 2 层 KAN 为 $[28, 32, 4]$, 65.0 KB 和 5.8% 周期利用率。 $[28, 64, 4]$ 变体超出 100 KB 工作内存限制, 证明内存——而非计算——是绑定约束。

深度缩放: 节点数以 $4L+2$ 线性增长, 内存以 $O(L \cdot d_{max}^2)$ 增长 (宽度二次, 深度线性)。4 层 KAN $[28, 16, 8, 4, 4]$ (18 节点, 40.0 KB, 3.9% WCET) 仍然可行, 确认实际 KAN 深度得以良好支持。

表 XIII
可扩展性: 宽度缩放 (KAN [28, d_{mid} , 4], $G=15$, S7-1200)

架构	内存	操作数	WCET	周期%	可行
[28, 8, 4]	17 KB	2,470	1,847 μs	1.9%	✓
[28, 16, 4]	33 KB	4,606	3,151 μs	3.1%	✓
[28, 32, 4]	65 KB	8,878	5,758 μs	5.8%	✓
[28, 64, 4]	129 KB	17,422	10,972 μs	11.0%	×

50 KB).

表 XIV
可扩展性: 深度缩放 (KAN [28, 16, ..., 4], $G=15$, S7-1200)

架构	内存	操作数	WCET	周期%	可行
[28, 16, 4]	33 KB	4,606	3,151 μs	3.1%	✓
[28, 16, 8, 4]	39 KB	5,462	3,736 μs	3.7%	✓
[28, 16, 8, 4, 4]	40 KB	5,634	3,886 μs	3.9%	✓

节点数: $4L+2$. 对固定 d_{max} , 内存随深度次线性增长. 2-4 层 KAN 全部在 S7-1200 预算内.

表 XV
可扩展性: 网格分辨率 (KAN [28, 16, 4], S7-1200)

G	内存	操作数	WCET	DA 界	安全因子
4	11 KB	4,518	2,948 μs	0.4683	27×
8	19 KB	4,562	3,050 μs	0.0860	146×
12	27 KB	4,606	3,151 μs	0.0348	361×
15	33 KB	4,606	3,151 μs	0.0215	584×
20	43 KB	4,650	3,252 μs	0.0117	1,076×

因子改善 40×. 精度-安全权衡强烈不对称, 有利于更高 G .

网格分辨率: 这是架构上最显著的轴。将 G 从 4 提高到 20, DA 安全因子从 27× 改善至 1,076×——形式正确性边界改善 40×——代价仅为 4× 更多 LUT 内存 (10.8→42.8 KB) 和 +10% WCET。DA 界按定理 1 二次改善 ($\propto 1/G^2$), 而二分搜索成本仅对数增长 ($\propto \log_2 G$), 产生强有力的缩放不对称性。这建立了有利的精度-安全权衡, 高保真 LUT 同时改善准确率和形式保证。

E6: 分类一致性。比较 PyTorch FP32 与 LUT 近似 (15 点): 在 CWRU 测试集 (1,000 样本) 上, 分类一致性 100%。对数级 MAE 0.15, MaxAE 3.65。逐元素 DA 界 (≤ 0.079) 低于最小类间边界 1.35。安全因子 8.5× 确认分类正确性不仅是经验观察——而是从数学保证的。IA 安全因子 3.9× 提供独立的最差情况证书。

E6-SMT: Z3 翻译验证。对 11 个 IR 节点的逐节点 Z3 SMT 翻译验证。9/11 节点证明精确代数等价 (Z3 UNSAT, < 12 ms/节点), 包括所有 MatMul、Add、StandardAct、Softmax 和 Argmax 节点。2 个 BsplineLUT 节点证明有界误差: $|\text{SCL}_{\text{LUT}}(x) - \phi_{\text{PyTorch}}(x)| \leq \epsilon_{\text{LUT}}$ 对所有 $x \in [a, b]$ 。证明时间: ~57 ms 总计 (IR 级模板验证) + ~285 ms/函数 (512 函数并行)。这是首次将翻译验证应用于 NN-to-PLC 编译器。

E7: 跨载荷泛化。仅在 1 hp 训练, 在未见载荷上测试: 0 hp 达 99.97% (2,467/2,468), 2 hp 达 100% (2,468/2,468), 3 hp 达 99.97% (2,467/2,468)。跨载荷准确率无退化——KAN 在域内分布偏移下享有与 CNN 教师相同的鲁棒性。

E8: 编译器优化消融。全流水线 (HoistBinarySearch + FuseMatMulAdd + LUTizeEXP + AdaptiveLUT) 实

表 XVI
编译器优化消融 (E8): KAN $\rightarrow$ S7-1200

启用传递	内存 (KB)	搜索/推理	估计加速	
无 (基线)	40.3	512	1.00×	
+ FuseMatMulAdd	35.5	512	1.05×	搜索/推理: 每推理 B 样条二分搜索操作数. 全部传递保持分类准确率 (仅代码生成). 内存值为编译器静态分析估计; 全流程 TIA V21 实测工作内存为 45.2 KB (表 VIII) .
+ HoistBinarySearch	40.3	44	1.35×	
+ LUTizeEXP	40.3	512	1.20×	
+ 全部三项	35.5	44	1.65×	

现累积内存减少 11.9% 和估计推理时间减少 35–50% (vs. 未优化基线)。HoistBinarySearch 单独贡献 $11.6\times$ 二分搜索减少 (512 $\rightarrow$ 44 每推理)。FuseMatMulAdd 每层节省 $d_{\text{out}} \times 4$ 字节。LUTizeEXP 消除 48 次软件 EXP 调用。AdaptiveLUT 在最差情况 LUT 误差上贡献 71.6% 减少。

E9: 可证明正确性。对训练 KAN [28, 16, 4] 在 $N = 15$ 处的完整正确性分析: IA 界 $\Delta_{\text{logit}} \leq 0.172$ (安全因子 $3.9\times$), DA 界 $\Delta_{\text{logit}} \leq 0.079$ (安全因子 $8.5\times$), DA/IA 直接紧致 $2.2\times$, 与 $\sqrt{d}$ 随机权重基线相比达 $3.1\times$ (§IV-B9)。分段感知 DA 贡献额外 $1.4\times$ 紧致, 组合安全因子 $\sim 11.9\times$ 。30 种子分布确认 $3.1\times$ 在均值 3.71 ± 0.81 的 23 百分位——代表性的, 非择优的。

E10: 极端稀疏 LUT。测试 3–50 点的 LUT 密度。即使 3 LUT 点 (6.0 KB 总计, 0.12 KB 每边), 分类准确率仍达 99.96%——在统一 15 点基线下仅下降 0.03 个百分点。KAN 可容忍极激进 LUT 压缩, 在良好分离分类任务上, 对存储受限部署具有直接意义。分类在 ≥ 3 点保持 $>99.9\%$ 准确率, 在 $N = 2$ 时降至 $\sim 92\%$ 。

E11: M_2 经验校准。跨全部 512 个 B 样条激活函数系统测量二阶导数最大值。特征 $M_2^{\text{char}} = 0.177$ (每函数最大中位数在 1,000 点网格上), 比保守解析界 $M_2^{\text{analytic}} \leq 12.8$ 紧致 98.6%。每函数分布重尾: 均值 0.607, 中位数 0.177, 最大值 1.586 (最差函数: L0, $\phi_{5,12}$, 在 $x^* = +0.090$ 处), 标准差 0.42。11.5% 的函数超过 $M_2 = 1.0$ 。此校准使能模型特定 LUT 误差界 (vs. 保守解析界), 是定理 1 使用 M_2^{char} 而非 M_2^{analytic} 的基础。

E12: 跨数据集迁移 (XJTU-SY)。零样本迁移准确率仅 29.8% (验证分割)。模型在域偏移下坍塌为单类预测。域间隙分析: MMD (CWRU vs XJTU-SY) = 0.044, 均值特征偏移 $|\bar{d}| = 0.84$ (z-score 单位), 最大偏移 $d = 7.40$ (第 22 维)。此间隙在 SVNN 框架预期内——定理 2 保证编译代码在验证域 (28-D 特征 $[-3, 3]^{28}$) 的误差界, 而非跨安装的模式准确率。

E12-FT (微调):在 XJTU-SY 训练分割上微调 100 轮 (冻结 B 样条基, 仅训练权重系数, $\text{lr} = 10^{-4}$)。准确率提升至 **91.7%** (+61.9 pp)。SVNN 条件保留: DA 界从 0.064 收紧至 0.049 (微调权重更平衡), Z3 保持 512/512, SCL 编译 0e 0w (2,188 行, S7-1200 53.4 KB)。微调不损害可验证性——SVNN 条件取决于架构而非特定权重值。

E13: 特征重要性消融。通过训练仅特征子集的 KAN 模型量化各组贡献: 时域仅 91.36%, 频域仅 99.93%, 离散熵仅 97.67%, 全 28-D 达 99.96% (微高于 E1 因不同随机种子)。频域组单独接近全 28-D 性能——对此数据集, 轴承故障以谱位移表现, 使频域特征特别信息丰富。多尺度离散熵 (RCMDE+RCHFDE) 提供互补非线性信息。

E14/E14-S: 对抗鲁棒性。高斯噪声测试: 在 $\sigma = 0.05, 0.1, 0.2$ 噪声水平下准确率无退化 (≤ 0.01 pp 波动)。

E14-S (对抗安全):进行最差情况对抗安全评估。在 5,000 随机输入上, 识别 LUT 误差最大的 100 个样本——问题不是随机输入上的原始一致性, 而是针对性最差情况是否翻转分类。在 5,000 输入中, FP32 和 LUT 预测在 99.8% 上一致 (10 个不匹配)。安全相关分析: 对最差 100 样本, FP32 和 LUT argmax 之间零分类翻转。在全部 5,000 输入中, 100/100 最差保持正确分类, 验证定理 1 的核心声明: LUT 近似不诱导分类错误。DA 界 0.079 恰表征中位数误差而非最差情况, 安全边界充足 (表 XVII)。

E15: 自适应混合精度 LUT。贪心最大堆算法 (算法 2) 比统一 $N = 15$ 分配将最差每函数 LUT 误差减少 **71.6%** (0.00115 vs. 0.00406)。等价地, 达到统一 $N = 15$ 最差情况误差水平仅需 17,888 字节——41.8% 存储节省。每

表 XVII
最差情况对抗安全: 5,000 随机输入, 最差 100 的 LUT-vs-FP32 分析

指标	值
总输入测试	5,000
FP32-LUT 一致 (全输入)	99.8%
最差 100 中分类翻转	0
最差样本 MaxAE (ℓ_∞ 逻辑)	3.65
中位数 AE (全 5,000 输入)	0.16
DA 逐元素界	≤ 0.079
最小类间边界	1.35
安全裁决	5,000 输入中零 LUT 致翻转

最差情况搜索以最大化 LUT 近似误差的针对性输入为目标, 而非中位数。

函数 N 范围从 3 到 28, 中位数 $N = 16$, IQR 13–19。定理 3 通过交换论证保证最优性; 经验间隙 vs. DP 最优仅 2.7%。跨 20 个预算水平平均间隙 3.1%。

E16: 分段感知 DA 验证。跨 512 个 B 样条激活函数和 $N = 15$ LUT 点: 逐段 ε_j 值平均比全局 ε 紧致 $6.0\times$ (均值 0.00069 vs. 0.00412)。96.7% 段有 $\varepsilon_j < 0.5\varepsilon_{\text{global}}$, 67.6% 有 $\varepsilon_j < 0.2\varepsilon_{\text{global}}$ 。与 DA 组合额外紧致 $1.4\times$ 。组合安全因子 $\sim 11.9\times$ ——构成编译 KAN 验证的已知最紧致算术界。

E17: RTNNIgen 编译器对比。七维对比: NeuroPLC 在正确性模型 (定理 1 vs. 测试集准确率)、模型支持 (KAN vs. Keras 密集层)、可审计证据 (Z3 证书 + DA 界 + 人类可读 ARRAY OF REAL vs. 浮点字面量)、目标 PLC (西门子 SCL vs. Beckhoff ST)、内存分析器 (静态分析 + TIA 实测 vs. 无)、优化传递 (四项传递 + 正确性证明 vs. 无) 和工程工作量量化 (2,610 $\times$ 加速 vs. 未报告) 方面差异显著。RTNNIgen [1] 提供了 ML 推理能够在 PLC 上原生运行的最强证据; NeuroPLC 增加了数学保证。

E18: 跨数据集迁移 (Paderborn)。零样本准确率 25.0% (KAt-DataGen, 轴承 6203, N09_M07_F10)。Paderborn 轴承数据集使用与 CWRU 不同的故障模式 (加速寿命测试 vs. EDM), 产生比 XJTU-SY 更大的域间隙。微调后 79.4% (冻结 B 样条基, 100 轮, $\text{lr} = 10^{-4}$)。Cohen's d 分析跨数据集识别了域不变特征候选 ($d \approx 0$ 的维数), 可用于指导域鲁棒特征选择。

E19: 方法边界分析。识别三个退化条件: (1) **DA**→**IA** (当权重符号完美对齐, $R \rightarrow 1.0$); (2) **自适应** → **均匀** (当 512 个 B 样条激活函数跨曲率多样性低时); (3) L_{net} **爆炸** (深度 ≥ 6 层时, 即使 $\gamma < 1$, 常数因子变得不切实际大)。这些不是失败模式而是正确性边界: 定理 1 的保证正确但变弱, 非无效。对实际 KAN 深度 ($L \leq 4$) 和典型权重符号分布 ($\sim 50/50$), 全部三个机制保持有效。

E20: 第二应用场景——电机载荷回归。相同编译器流水线无需修改应用于回归任务: KAN [28, 16, 1] (输出维 = 1, MSE 损失), 回归 RMSE 0.011。SCL 生成 1,125 行, 0e 0w TIA Portal 编译。任务变更零编译器修改 (~ 30 秒重运行)。证明编译器对不同预测任务 (分类和回归) 和数据模态的通用性——28-D 特征结构是唯一的领域特定组件。

E52: 验证盲点。在 $N = 4, 5$ 时, 测试准确率保持 99.93% 但 SVNN 安全因子 (IA) 降至 < 1 ——经验准确率与数学正确性保证之间存在盲点。对抗搜索在测试集遗漏的 $N = 4$ 处发现 225/20,000 真实误分类。此为编译器集成 `auto_bspline` 传递的实例: 强制最小安全因子 $2.0\times$ 作为硬部署门 ($N \geq 7$), 确保数学保证与经验准确率之间不存在盲点。

E54: ChebyKAN Z3 验证。ChebyKAN [28, 16, 4], Chebyshev 度 $N = 5$ (每边 5 个 Chebyshev 基函数), 总参数 5,636。CWRU 准确率 100.0%。Z3 逐函数验证: 496/512 可验证 (96.9%)——略低于 KAN 样条的 512/512, 因 Chebyshev 多项式在域边界附近具有更高 M_2 曲率。证明 Chebyshev 多项式满足命题 2 (SVNN 条件 2), 将可验证架构家族从 B 样条 KAN 扩展到正交多项式 KAN。

E55: XJTU-SY 微调 + SCL。100 轮微调达到 91.7%, 512/512 Z3 保留 (预微调可验证性在适应后不退化),

SCL 编译 0e 0w (2,188 行, S7-1200 53.4 KB)。DA 界从 0.064 收紧至 0.049——微调改善可验证性, 因为域内数据产生更平衡的权重符号。

E56: 深层 KAN ($L = 3$)。KAN [28, 16, 8, 4], 训练 120 轮 (Adam, lr= 0.003, 余弦退火), 99.60% CWRU 准确率。608/608 (100%) Z3 逐函数验证——深度增长不损害可验证性 (定理 4 预测)。DA 界相比 2 层 KAN 增长 $14.6\times$ ($\sim 7.3\times$ /层)——线性增长而非指数, 确认定理 4 的 γ^L 收敛。无组合证书破坏。

E57: CROWN 对比。将 NeuroPLC DA 与 CROWN-IBP [29] 在相同 KAN [28, 16, 4] 上对比。NeuroPLC DA $\Delta = 0.064$ (编译 LUT 近似界) vs. CROWN-IBP $\Delta = 5.45$ (模型鲁棒性界)——**紧致 $85\times$** 。CROWN 对 KAN 无天然优势: KAN 已经是分段线性的——无需松弛 ReLU——因此 CROWN 的线性松弛优势在此不适用。DA 利用编译器知识 (精确 LUT 误差分布、权重符号结构), 而 CROWN 以通用模型鲁棒性为目标。NeuroPLC DA 提供编译级认证, CROWN 提供模型鲁棒性认证——两种互补但不竞争。

VI. 讨论

A. 为什么 KAN 可编译——三个结构性原因

先前 ML $\rightarrow$ PLC 工具的预期是任何神经网络均可编译——仅工程工作量不同。我们的发现反驳了此预期: 是否能以设计时正确性保证编译取决于架构, 而非努力。同一编译器、同一 LUT 机制: KAN 512/512 Z3 验证 vs. MLP 0/48, $14.0\times$ 逐组件误差传播差距 (端到端 $38\times$)——这不能归因于实现细节或调试不够。它是结构性的, 且 SVNN 框架提供了形式化解释。

正确性论证建立在三个可组合机制上, 其合成——而非任一单独机制——产生端到端保证。这些机制并非各自新颖; 它们的组合才是。该组合之所以可能, 是由 KAN 架构的三个相互关联的结构性质所驱动:

第一, 结构离散化——局部基的价值。B 样条基函数具有局部支撑: 每个 $B_{c,3}(x)$ 在至多 4 个相邻节点区间上非零。此局部性直接使能分段感知 de Boor 界 ($6.0\times$ 紧致): 二阶导数 $|\phi''(x)|$ 在每个 LUT 段上的最大值仅依赖于该段覆盖的基函数的贡献, 而非整个域的全局最差情况。MLP 的 SiLU/Sigmoid/Tanh 在实数线上全局定义且非分段二次可微, 排除了对每个 MLP 激活的这种逐段紧致性 (命题 1)。局部基不是 KAN 的可选特征——它对可验证性至关重要。

第二, 参数紧凑性——单变量结构的直接后果。 $7.9\times$ 压缩 (6,148 vs. 48,708 参数) 适配 PLC 内存, 但更重要的是, 参数对可验证性的分布方式。KAN 的每条边学习一个单变量函数——一个数学上清晰的实体, 具有良好定义的 M_2 曲率界——使得每个激活函数的 LUT 近似误差可单独且先验界定。在 MLP 中, 跨神经元的参数相互作用产生隐式特征交互, 对任何给定的参数子集均匀界定误差传播。512 个 KAN 激活函数每函数仅需 68 字节 LUT 存储; 等价的 MLP 密集层无法如此经济地离散化。

第三, 可解释性——可验证性的定性表现。学习 B 样条激活可逐条可视化、检查和审计 (图 4)。这不是美学——它对安全认证具有操作意义。当安全评估员问“神经网络将输入 x_{12} 映射到什么值?” 时, KAN 回答是明确的: B 样条激活 $\phi_{5,12}$, 其 LUT 在 DB200 偏移处, 其 M_2 为该特定函数测量。在 MLP 中不存在此粒度——评估员接收跨越多个隐藏单元和层的分布式表示。可解释性和可验证性在 KAN 中是同一结构性质的两个侧面: 单变量分解使函数既可被人类审计员检查, 又可被数学上限界定。

深度缩放 (E56)。3 层 KAN 的 608/608 Z3 验证 (100%) 确认了理论预测 (定理 4): 深度增长不损害可验证性——DA 界随深度线性增长 ($14.6\times$, $\sim 7.3\times$ /层) 而非指数。这是定理 6 (收缩性) 和定理 4 (随机符号模型) 的直接结果, 且具有重要操作意义: 多层 KAN ($L \leq 5$) 在当前 PLC 内存预算下仍可验证, 可编译深度极限由内存决定 (表 XIV), 而非由正确性保证。

CROWN 对比 (E57): 认证编译器 vs. 通用验证器。NeuroPLC DA 比 CROWN-IBP 紧致 $85\times$ 。这不仅是性能差异——CROWN 的架构——为 ReLU 网络上逐层线性松弛传播而设计——在无 ReLU 要松弛的网络上自然失去其核心操作。选择可验证架构使编译器实现通用验证器无法匹配的界, 因为编译器可以利用特定于架构的知

识（确切的 LUT 误差分布、权重符号结构），而通用验证器必须处理所有可能的网络拓扑。85× 因子量化了在为可验证性设计的模型上，领域特定认证相比于通用验证的价值。

B. 端到端组合验证：三层架构

对 3,800 行 SCL 程序的单体 SMT 验证将超时——这是标准形式化方法的暴露——因此 SVNN 框架通过将验证分解为三个独立层级提供了不同路径：

- 1) **层级 1——编译器模板验证（一次性，4/6 IR 操作类型）**。Z3 证明 4 种操作类型的 SCL 代码模板对所有可能参数（权重、偏置、网格、LUT 表）正确。这是编译器级保证：证明的不是“此特定模型正确编译”，而是“此编译器对任意 SVNN 编译正确”。BsplineLUT 和 Softmax 因浮点舍入保持有界而非精确。
- 2) **层级 2——逐函数实例验证（512/512 并行 Z3 证明）**。每个样条激活函数的专用 Z3 证明（UNSAT, ~285 ms/函数）。该层级将编译器级保证连接到此特定模型的编译。证明是尴尬并行的（512 个独立 Z3 实例），使其适用于 CI/CD 流水线。
- 3) **层级 3——组合证书（~200 行可信检查器）**。从 512 个逐函数证明中提取边界，通过 ~200 行可信检查器组装为端到端证书。检查器的逻辑对应定理 1 的结构归纳：它验证层 0 BsplineLUT 误差 → MatMul L1 范数 → 层 1 传播 → Softmax 压缩 → Argmax 保持。组合步骤不调用 Z3——它执行确定性算术（乘法和加法），自身在其指令上的 $\ll 1$ ms 内可审计。

结果：模板验证 57 ms（一次性），512/512 逐函数 UNSAT 在 1,431 ms（~285 ms/函数），组合证书在 ~228 ms 内有效。总验证时间 1,716 ms——低于典型 CI 作业持续时间，且嵌入模型训练-编译流水线。这是在编译器模板级别形式验证的首个工业控制器神经网络编译器。

C. KAN vs. MLP 验证差距：对一个反直觉结果的理论解释

结果量化了一个结构性差距，而非程度差异：KAN [28, 16, 4] 达 512/512 Z3 验证，端到端证书有效；MLP [28, 32, 16, 4] 仅 0/48 Z3 验证。误差传播差 $14.0\times$ （DA 逐组件）和 $17.7\times$ （IA），无组合证书可能。

这不是因为 MLP 被任意惩罚——完全相同的编译器流水线、相同的 LUT 离散化机制和相同的 Z3 编码应用于二者。差距产生于定理 5（违反 SVNN 条件使紧致界计算 NP 难）和命题 1（标准 MLP 激活违反条件 1-2）共同作用：

- MLP 的 SiLU 激活耦合了两个操作——门控（ $\sigma(x)$ ）和缩放（乘以 x ）——违反了操作类型封闭性（条件 1）。这迫使编译器将每个激活视为需要独立 LUT 的原子操作，但 SiLU 的二阶导数在实数线上无界（ $\lim_{x \rightarrow \infty} |\text{SiLU}''(x)| = 0$ ，但在 $[-3, 3]$ 上可达 ~1.1），违反条件 2。
- MLP 的 MatMul 随后的 SiLU 激活 $\sigma(Wx + b)$ 无法分解为独立的单变量函数——对 W 一列的误差传播通过 σ 的非线性与其他列耦合。Z3 遭遇混合整数非线性约束，在 ~48 变量下超时。
- KAN 的分解 $\sum_i \phi_{j,i}(x_i)$ 是前提：每个 $\phi_{j,i}$ 是单变量——使 Z3 能够独立处理每个 B 样条函数——且仅在 MatMul 阶段出现线性交互。Z3 以线性算术完美处理这些交互（9/11 节点证明精确等价）。

这提供了选择 KAN 的严格验证理论依据，独立于准确率：架构选择关乎可验证性，而非表达能力。当安全认证为硬要求时，KAN 的可验证性与 MLP 的不可验证性之间的壁垒就成为了决定因素。

D. 跨域流水线通用性

相同编译器流水线应用于三个数据域——CWRU（99.93% 轴承故障）、XJTU-SY（91.7% 微调自然退化）、MNIST（98.6% 手写数字）——产生一致验证保证且零流水线修改。CWRU→XJTU-SY 迁移揭示重要不对称性：零样本仅 29.8%（域间隙：MMD=0.044），而微调在保持 512/512 Z3 完整性同时恢复 91.7%。关键观察：微调改善了可验证性（DA 界从 0.064 收紧至 0.049）——机制是：域内训练产生更平衡的权重符号，增强 DA 抵消。

ChebyKAN (命题 2) 实现了 100.0% CWRU 准确率和 496/512 Z3 可验证性 (96.9%), 确认正交多项式基满足 SVNN 条件 2, 且可验证架构家族不限于 B 样条 KAN。这对实际部署有意义: 当 B 样条 KAN 的训练动态欠佳 (高曲率权重) 时, ChebyKAN 提供了具有类似可验证性保证的替代方案。

E. 设计理念与差异化: LLM、ONNX 与 SVNN

三个竞争方法被排除——以经验论证和根本原因分析为依据:

为何不用 LLM 代码生成? Claude (2026 年 6 月) 被要求生成 SCL 推理代码, 结果包含 6 个关键缺陷 (V2 验证): 权重数组初始化缺失、KAN 层公式错误 (双和公式不正确)、西门子特定语法超出 PLC 内存预算、冗余变量声明、无类型注解、无 DB 块结构。这些不是 LLM 缺陷——它们在任何随机过程面对确定性 IEC 61131-3 编译器的结构后果。更根本的是: LLM 输出是随机的, 违反 IEC 61508 要求的确定性; 不提供数学正确性保证; 且无法对每次模型重训练重新审计。即使 LLM 今天碰巧为特定模型和架构生成了正确代码, 它无法提供定理 1 的保证——即代码对所有可能输入保留 PyTorch 语义的数学保证。

为何不用 ONNX? ONNX 标准缺乏 B 样条算子 (截至运算符 v21), 因此 KAN 导出必须分解为基本 ONNX 原语 (Mul、Add、Sigmoid、Exp)。此分解产生 $\geq 8,393$ 个图节点 vs. NeuroPLC 的 11 个——**763× 爆炸**——因为每个 B 样条函数变成数十个 ONNX 节点, 以标准格式表示的 $O(K \cdot d_{\text{out}} \cdot d_{\text{in}})$ 节点。即使能导出, ONNX Runtime 最小库 (~22 MB) 超 S7-1200 工作内存 **450×**, 且 ONNX Runtime 不支持 IEC 61131-3 作为后端目标。ONNX 是正确的通用 ML 互操作工具——但对于资源受限 PLC 上的认证 NN 部署, 它是错误的技术选择。

为何 SVNN 非 ONNX 非 LLM? SVNN 不试图将任意神经网络编译到 PLC——它重新定义了问题: 不是“如何为任意网络构建更好的编译器”, 而是“哪些网络使编译可认证?” 这重新定义使一个包含 6 种 IR 操作类型、11 个节点和 3,800 行确定性 SCL 的紧凑编译器能够提供数学正确性保证——ONNX (通用互操作性、无 B 样条算子) 和 LLM (随机输出、无可审计保证) 都结构上无法提供的特性。

F. 统计有效性与局限性

第一, 无物理 PLC 测量。所有时序从指令计数、S7-1200 手册标称时序 (REAL 加 $0.50 \mu\text{s}$ 、乘 $0.60 \mu\text{s}$ 、除 $1.20 \mu\text{s}$) 和 Z3 WCET 分析估算。物理硬件时序可能因固件特定因素 (内存控制器延迟、总线争用、DB 访问模式) 而异。将此限制放入背景: 此论文的贡献是软件级正确性论点——定理 1 的保证独立于执行时序——物理测量是部署认证障碍, 而非正确性障碍。TIA Portal V21 编译 (0e 0w) 确认了代码的句法和语义正确性; 物理 PLC 执行提供额外的运行时验证。我们将此标识为向 IEC 61508 认证的下一个自然步骤, 且是可解决的: 西门子 PLCSIM Advanced 支持确定性的指令精确时序建模。

第二, 正确性保证范围。定理 1 证明在第 §IV-B12 中定义的 IEEE 754 抽象机中编译代码与 PyTorch 模型之间的语义保持。这覆盖了所有软件级错误源 (LUT 近似、浮点舍入、算术误差传播), 但不构成对所有可能硬件输入 (电磁干扰、电压波动、热效应) 的机器检查证明——这些是 PLC 供应商针对 IEC 61131-2 认证处理的设计保证。编译器的前馈架构支持, CWRU 数据集限制 (已知局限的学术基准), 以及西门子特定 SCL 后端, 是工业编译器的标准范围限制。

第三, 训练鲁棒性。CWRU 数据集具有已知局限: EDM 诱导故障可能不代表运行退化, 测试条件为实验室而非工业。我们在 E12–E18 中通过跨数据集迁移实验 (XJTU-SY 和 Paderborn, 真实轴承退化) 局部缓解了这一点。跨数据集微调保留了可验证性, 为更具鲁棒性的工业部署提供了原则性路径。

第四, 可扩展性边界。定理 4 的 $\gamma < 1$ 条件确保期望误差收敛到与深度无关常数。但对 $L \geq 6$ 层, 常数因子 $d_{\text{max}}/(1 - \gamma)$ 变得不切实际大, 即使误差不随深度进一步增长。E56 ($L = 3$, DA 界 $14.6 \times$) 和 E5 深度缩放 (4 层仍可行) 确认深度 ≤ 5 是目前实际可验证范围——由 PLC 内存而非误差积累约束。

G. 通向功能安全认证的路径

SVNN 框架直接映射到新兴 AI 功能安全标准的四个核心要求：ISO/IEC TS 22440 [55] 要求可审计性（白盒模型检查——定理 1 提供）、输入域规范（验证域 $[-3, 3]$ ²⁸——阶段 1 界定）、边界情况覆盖（对抗验证——E14-S 和 E52 保证）和确定性（编译器输出非随机——表 IX 和 V2 LLM 对比证实）。

两个认证层级浮现：

- 1) **高概率层级 (SIL 2)**。使用 DA（安全因子 $8.5\times$ 于 $N = 15$ ），由引理 3 的随机符号模型支撑（95% 置信度），E14-S 对抗验证支持。适用于在非安全关键背景下需要可信正确性保证的监管应用。
- 2) **可靠层级 (SIL 3)**。使用分段感知 IA（安全因子 $3.9\times$ 于 $N = 15$ ， $11.9\times$ 于 $N \geq 20$ 结合 DA），提供了零概率假设的最差情况保证。IA 界不依赖任何符号或权重分布的假设——仅依赖 de Boor 插值界（纯数学事实，自 1978 年起）和范数界（三角形不等式）。

这勾勒了路径——而非完整认证。贡献是软件级别正确性论点：编译器产生的代码以机器可检查的证据（Z3 证书 + 组合证书 + DA 算术界）在可计算误差界内忠实于训练后的 PyTorch 模型。这是 AI 功能安全认证中当前缺失的拼图——先前 PLC 上 ML 推理的工作提供了经验验证（RTNNIgen）或形式化逻辑验证（ESBMC-PLC+）但非二者的组合。ESBMC-PLC+ 可以验证由 NeuroPLC 生成的 SCL 代码的逻辑属性；NeuroPLC 提供该代码忠实于其源 PyTorch 模型的数学保证。二者组合覆盖了安全论证的两半——代码做其声称的事，且该声称是预期的事。

H. 未来工作

七条方向：(1) **物理 PLC 测量**——通过 PLCSIM Advanced API 或 python-snap7 通道，在 S7-1200 CPU 1211C 上流式 1,000 样本测试集对比裸机时序和 Z3 WCET 预测，弥合软件级正确性与硬件级验证之间的剩余间隙；(2) **OPC UA 集成**——将生成的 SCL 包装进 OPC UA 信息模型，实现在西门子工业边缘生态系统中的即插即用部署；(3) **架构扩展**——将编译器支持扩展到轻量 Transformer 变体（SVNN 兼容架构），将 ChebyKAN 证明技术扩展到其他正交多项式基（Legendre、Hermite）；(4) **理论收紧**——探索将定理 5 的 NP 难结果收紧为常数因子不可近似性（Unique Games Conjecture 下），将泛化界（定理 6）从收缩区域（ $\gamma < 1$ ）扩展到 $\gamma \geq 1$ 的过渡区域；(5) **安全认证试点**——与认证机构合作，以 SVNN 框架作为软件级安全论据，对隔离安全功能进行 IEC 61508 SIL 2 预评估；(6) **PLCSIM Advanced 验证回路**——在西门子 PLCSIM Advanced 虚拟 CPU 上运行完整 TIA 项目，通过虚拟背板比较运行时逻辑与 PyTorch 参考；(7) **多目标后端**——将编译器后端从 S7-1200/S7-1500 扩展到其他 IEC 61131-3 平台（Beckhoff TwinCAT、Codesys、B&R Automation Studio），展示 SVNN 框架的平台独立性。

VII. 结论

IEEE 754 浮点标准是确定性的，但此前无一 PyTorch-to-PLC 编译器能认证其输出保留训练模型行为。本文证明障碍不在浮点复杂度——而在架构。当神经网络分解为纯线性和逐元素单变量操作（SVNN 条件 1-2），编译器可从模型参数单独计算对所有输入有效的有限逐输出误差界。当不满足时，问题变为 NP 难（定理 5）。KAN 满足这些条件；标准 MLP 不满足。这就是**可编译前沿**——本文首要贡献。

四项结果支撑：(1) 完整理论（6 定理 + 2 命题）：充分性 $\rightarrow$ 必要性 $\rightarrow$ 泛化理论完全闭合。(2) 组合验证：三层架构分解问题为一次性模板证明 + 逐函数实例 + ~ 200 行可信检查器。(3) 结构性验证差距： $38\times$ 误差传播差距是架构性的，跨数据集和架构持续存在。(4) 编译器实际工作：0e 0w TIA Portal V21 编译，深度缩放确认理论预测。物理 PLC 测量仍是向 IEC 61508 部署认证的关键下一步。

本文回答的问题不是“能否编译”——先前工具已证明可以。问题是“能否认证该编译”。答案取决于架构而非工程工作量。”从验证编译器到设计可验证架构”这一重构是将比任何特定编译器实现更持久的贡献。


代码与数据可用性

所有代码和检查点发布于<https://github.com/aiyuedi/neuroplc>。

参考文献

- [1] C. Hinze, Z. Zhou, H. Xu, A. Lechler, and A. Verl, “RTNNigen — An Open-Source PLC Library and Python Generator Converting Keras Models to Realtime Capable Structured Text,” in *IECON 2024 — 50th Annual Conference of the IEEE Industrial Electronics Society*, 2024.
- [2] N. Campos, A. Pereira, D. Duarte, F. Perez, G. Pessin, and M. Pinto, “A Conversion Tool for Translating Python-Based Machine Learning Models to Structured Text Codes,” *SoftwareX*, vol. 29, p. 102005, 2025.
- [3] C. Doumanidis, P. H. N. Rajput, and M. Maniatakis, “ICSML: Industrial Control Systems ML Framework for Native Inference Using IEC 61131-3 Code,” in *ACM Workshop on Cyber-Physical Systems Security & Privacy (CPSS)*, 2023.
- [4] G. F. da Silva Corrêa, “Avaliação de redes neurais artificiais em controladores lógicos programáveis para classificação de dados,” Master’s thesis, Universidade de São Paulo (USP), 2024, first KAN-on-PLC demonstration via Snap7 distributed execution; MLP achieved 98% on S7-1511TF, KAN achieved 88.5% (distributed). No native SCL compilation, no correctness guarantees.
- [5] L. Hoang, A. Gupta, and D. M. Harris, “KANELÉ: Kolmogorov-Arnold Networks for Efficient LUT-Based Evaluation,” in *ACM/SIGDA International Symposium on Field-Programmable Gate Arrays (ISFPGA)*, 2026, best Paper Award.
- [6] A. Kuznetsov, “LUT-KAN: Efficient B-Spline Activation via Precomputed Lookup Tables for Embedded Inference,” *Neurocomputing*, 2026.
- [7] Anonymous, “Kolmogorov-arnold networks under tinyml constraints: A study on SoC estimation for electric vehicles,” in *IEEE International Conference on Emerging Technologies and Factory Automation (ETFA)*, 2025, KAN achieved 10× smaller memory (693 bytes vs. 6,807 bytes) vs. MLP on microcontrollers with competitive accuracy.
- [8] N. Schwartz, C. K. Nagesh, S. Sankaranarayanan, R. Kaur, T. Sahai, and S. Jha, “Optimal Abstractions for Verifying Properties of Kolmogorov-Arnold Networks (KANs),” *arXiv preprint arXiv:2602.06737*, 2026, pWA abstraction + MILP encoding for KAN formal verification.
- [9] Z. Liu, Y. Wang, S. Vaidya, F. Ruehle, J. Halverson, M. Soljačić, T. Y. Hou, and M. Tegmark, “KAN: Kolmogorov-Arnold Networks,” *arXiv preprint arXiv:2404.19756*, 2024.
- [10] W. Zhang, F. Xie, W. Cai, and C. Ma, “VRM: Knowledge Distillation via Virtual Relation Matching,” in *Proceedings of the IEEE/CVF International Conference on Computer Vision (ICCV)*, 2025, pp. 2707–2717.
- [11] CWRU Bearing Data Center, “Case Western Reserve University Bearing Data Center,” <https://engineering.case.edu/bearingdatacenter>, 2024, accessed: 2026-07-04.
- [12] W. Zhang, G. Peng, C. Li, Y. Chen, and Z. Zhang, “A New Deep Learning Model for Fault Diagnosis with Good Anti-Noise and Domain Adaptation Ability on Raw Vibration Signals,” *Sensors*, vol. 17, no. 2, p. 425, 2017.
- [13] W. Zhang, X. Li, and Q. Ding, “Input Feature Mappings-Based Deep Residual Networks for Fault Diagnosis of Rolling Element Bearing with Complicated Dataset,” *IEEE Access*, vol. 8, pp. 175 157–175 167, 2020.
- [14] H. Azami, M. Rostaghi, D. Abásolo, and J. Escudero, “Refined Composite Multiscale Dispersion Entropy and its Application to Biomedical Signals,” *IEEE Transactions on Biomedical Engineering*, vol. 64, no. 12, pp. 2872–2879, 2017.
- [15] Y. Chen *et al.*, “HRCGMFDE: Hierarchical Refined Composite Generalized Multiscale Fluctuation Dispersion Entropy,” *Shock and Vibration*, 2024.
- [16] T. W. Rauber, F. de Assis Boldt, and F. M. Varejão, “An Experimental Methodology to Evaluate Machine Learning Methods for Fault Diagnosis Based on Vibration Signals,” *Expert Systems with Applications*, vol. 167, p. 114022, 2021.
- [17] S. Rigas, P. Tzouveli, and S. Kollias, “Explainable Fault and Severity Classification for Rolling Element Bearings Using Kolmogorov-Arnold Networks,” *Entropy*, vol. 27, no. 4, p. 403, 2025.
- [18] Y. Wang *et al.*, “Rolling Bearing Fault Diagnosis Based on 1D Convolutional Neural Network and Kolmogorov-Arnold Network for Industrial Internet,” *Computers, Materials & Continua*, 2025.
- [19] K. Zhang *et al.*, “Efficient Fault Diagnosis in Industrial Systems Using Enhanced PolyKAN Techniques,” *IEEE Transactions on Industrial Informatics*, vol. 22, no. 3, 2025.
- [20] A. Tankman, “Layer-wise Lipschitz-Product Control for Deep Kolmogorov-Arnold Network Representations of Compositionally Structured Functions,” *arXiv preprint arXiv:2604.26444*, 2026, proves $P(KAN) \leq 1$ for standard operation sets on bounded domains.
- [21] Y. Zhang, J. Lv, W. Lin, and Z. Ding, “Formal Synthesis of Safe Kolmogorov-Arnold Network Controllers with Barrier Certificates,” in *Proceedings of the International Joint Conference on Artificial Intelligence (IJCAI)*, 2025, pp. 302–310.
- [22] M.-L. Schumacher, B. Heiderich, and M. F. Huber, “Training and Verifying Robust Kolmogorov-Arnold Networks,” in *International Conference on Learning Representations (ICLR)*, 2025, openReview: N9hl7CSHRA.
- [23] D. Zhang, “PolyKAN: Provable and Optimal Compression of Kolmogorov-Arnold Networks,” *arXiv preprint arXiv:2510.04205*, 2025.
- [24] G. Hinton, O. Vinyals, and J. Dean, “Distilling the Knowledge in a Neural Network,” *arXiv preprint arXiv:1503.02531*, 2015.
- [25] X. Ren *et al.*, “Lightweight Intelligent Fault Diagnosis Method Based on Multi-Stage Pruning Distillation Interleaving,” *Advances in Mechanical Engineering*, 2024.

- [26] P. Dantas, W. Junior, and L. Cordeiro, “ESBMC-PLC+: A Unified IEC 61131-3 Formal Verification Framework as a PLCverif Successor,” *arXiv preprint arXiv:2606.23870*, 2026, sMT-based bounded model checking + k-induction for LD/ST/SCL.
- [27] M. C. Werner, “Model-Based Design of Program Organization Units Using Synchronous Languages,” Ph.D. dissertation, University of Kaiserslautern-Landau, 2025.
- [28] M. Ebrahimi Salari, E. Enouï, C. Seceleanu, and R. Eilers, “PyLC+: A Verification-Aware Pipeline for PLCs,” in *IEEE International Conference on Computers, Software, and Applications (COMPSAC)*, 2025.
- [29] H. Zhang, T.-W. Weng, P.-Y. Chen, C.-J. Hsieh, and L. Daniel, “Efficient neural network robustness certification with general activation functions,” in *Advances in Neural Information Processing Systems (NeurIPS)*, 2018.
- [30] G. Singh, T. Gehr, M. Puschel, and M. Vechev, “An abstract domain for certifying neural networks,” in *Proceedings of the ACM on Programming Languages (POPL)*, 2019.
- [31] S. Wang, H. Zhang, K. Xu, X. Lin, S. Jana, C.-J. Hsieh, and J. Z. Kolter, “Beta-crown: Efficient bound propagation with per-neuron split constraints for neural network robustness verification,” in *Advances in Neural Information Processing Systems (NeurIPS)*, 2021.
- [32] G. Katz, C. Barrett, D. L. Dill, K. Julian, and M. J. Kochenderfer, “Reluplex: An efficient smt solver for verifying deep neural networks,” in *International Conference on Computer Aided Verification (CAV)*, 2017.
- [33] G. Katz, D. A. Huang, D. Ibeling, K. Julian, C. Lazarus, R. Lim, P. Shah, S. Thakoor, H. Wu, A. Zeljic, D. L. Dill, M. J. Kochenderfer, and C. Barrett, “The marabou framework for verification and analysis of deep neural networks,” in *International Conference on Computer Aided Verification (CAV)*, 2019.
- [34] M. Mirman, T. Gehr, and M. Vechev, “Differentiable abstract interpretation for provably robust neural networks,” in *International Conference on Machine Learning (ICML)*, 2018.
- [35] S. Gowal, K. Dvijotham, R. Stanforth, R. Bunel, C. Qin, J. Uesato, T. Mann, and P. Kohli, “On the effectiveness of interval bound propagation for training verifiably robust models,” in *ArXiv preprint*, 2018.
- [36] Y. Li, J. Avigad *et al.*, “TorchLean: A Formally Verified IEEE-754 Floating-Point Kernel for Neural Network Verification in Lean 4,” *arXiv preprint arXiv:2602.22631*, 2025.
- [37] C. de Boor, *A Practical Guide to Splines*, 1st ed. Springer-Verlag, 1978.
- [38] D. Richardson, “Some undecidable problems involving elementary functions of a real variable,” *The Journal of Symbolic Logic*, vol. 33, no. 4, pp. 514–520, 1969.
- [39] Z. Bozorgasl and H. Chen, “Wav-KAN: Wavelet kolmogorov-arnold networks,” 2024, includes ChebyKAN variant using Chebyshev polynomial basis functions.
- [40] A. A. Markov, “On a problem of D. I. Mendelev,” *Izvestiya Akademii Nauk*, 1916, reprinted in *Collected Works*, 1948. Contains the Markov Brothers’ Inequality: $||p'| \leq n^2 ||p|$ for polynomials on $[-1, 1]$.
- [41] H. Zhang, S. Wang, K. Xu, L. Li, B. Li, S. Jana, C.-J. Hsieh, and J. Z. Kolter, “General cutting planes for bound-tightening in neural network verification,” in *Advances in Neural Information Processing Systems (NeurIPS)*, 2022, α - β -CROWN verifier.
- [42] P. L. Bartlett and S. Mendelson, “Rademacher and Gaussian complexities: Risk bounds and structural results,” *Journal of Machine Learning Research*, vol. 3, pp. 463–482, 2002.
- [43] S. Boucheron, G. Lugosi, and P. Massart, *Concentration Inequalities: A Nonasymptotic Theory of Independence*. Oxford University Press, 2013.
- [44] W. Li, S. Xu, G. Zhao, and L. P. Goh, “Adaptive Knot Placement in B-spline Curve Approximation,” *Computer-Aided Design*, vol. 37, no. 8, pp. 791–797, 2005.
- [45] L. Piegl and W. Tiller, *The NURBS Book*, 2nd ed. Springer, 1997.
- [46] K. E. Atkinson, *An Introduction to Numerical Analysis*, 2nd ed. John Wiley & Sons, 1989.
- [47] P. Krukowski, D. Wilczak, J. Tabor, A. Bielawska, and P. Spurek, “Make Interval Bound Propagation Great Again,” *arXiv preprint arXiv:2410.03373*, 2024.
- [48] J. Stolfi and L. H. de Figueiredo, “An introduction to affine arithmetic,” *TEMA: Trends in Applied and Computational Mathematics*, vol. 4, no. 3, pp. 297–312, 2003.
- [49] Siemens AG, *SIMATIC S7-1200 Programmable Controller System Manual*, 4th ed., 2022, cPU 1211C AC/DC/Relay: 75 kB work memory.
- [50] W. A. Smith and R. B. Randall, “Rolling Element Bearing Diagnostics Using the Case Western Reserve University Data: A Benchmark Study,” *Mechanical Systems and Signal Processing*, vol. 64–65, pp. 100–131, 2015.
- [51] J. Hendriks, P. Dumond, and D. A. Knox, “Towards Better Benchmarking Using the CWRU Bearing Fault Dataset,” *Mechanical Systems and Signal Processing*, vol. 169, p. 108732, 2022.
- [52] A. Paszke, S. Gross, F. Massa *et al.*, “PyTorch: An Imperative Style, High-Performance Deep Learning Library,” in *Advances in Neural Information Processing Systems (NeurIPS)*, vol. 32, 2019.
- [53] W. Park, D. Kim, Y. Lu, and M. Cho, “Relational Knowledge Distillation,” in *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, 2019, pp. 3967–3976.
- [54] L. van der Maaten and G. Hinton, “Visualizing Data using t-SNE,” *Journal of Machine Learning Research*, vol. 9, pp. 2579–2605, 2008.
- [55] ISO/IEC JTC 1/SC 42, “ISO/IEC TS 22440: Artificial Intelligence — Functional Safety and AI Systems,” International Organization for Standardization, Tech. Rep., 2026, under development; first international standard for AI functional safety.



刘 甫悦，桂林电子科技大学智能制造工程专业在读本科生。研究方向包括工业 AI、神经网络编译和形式化验证方法。